

UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE INGENIERÍA
Departamento de Ingeniería Informática



**Optimización multi-objetivo para seleccionar modelos de señales
biológicas**

Diego Alberto Vallejos Galvez

Profesor Guía: José Luis Jara
Trabajo de titulación
presentado en conformidad a
los requisitos para obtener el
título de Ingeniero Civil en
Ingeniería Informática.

Santiago – Chile
2017

© Diego Alberto Vallejos Galvez, 2017.

Algunos derechos reservados. Esta obra está bajo una Licencia Creative Commons Atribución-Chile 3.0

RESUMEN

La autorregulación cerebral es un concepto que no posee una manera estándar de ser medida, por lo que diferentes técnicas han sido desarrolladas para modelar este comportamiento. El objetivo es obtener variados modelos, seleccionar uno que capture el fenómeno de la autorregulación y cuantificar su valor. Para esto se utilizan los índices *Auto-Regulation Index* (ARI) y *model free Auto-Regulation Index* (mfARI), teniendo este último menor variabilidad entre sujetos en igualdad de condiciones. Recientemente, se ha implementado una mejora a la etapa de selección, que automatiza el proceso basándose en las características de la señal. Pero esta estrategia evalúa solo a los modelos de más alta correlación, forzando a la búsqueda exhaustiva.

El objetivo es realizar un análisis con optimización multi-objetivo (OMO), y compararlo con el enfoque actual usando índices ARI, mfARI y un índice de calidad basado en la diferencia de los índices obtenidos y las señales reales. Con técnicas OMO se podría acotar el espacio muestral con resultados significativamente iguales a los del método estándar.

Se usaron modelos multivariados del tipo *finite impulse response* (FIR) y *auto-regressive with exogenous inputs* (ARX), ambos del tipo lineal y no lineal (NFIR y NARX), como estructuras para el aprendizaje de las máquinas de vectores soporte. Los datos corresponden a 16 sujetos de los cuales se obtuvo la Presión Arterial Media (PAM), Velocidad de Flujo Sanguínea Cerebral (VFSC) y la presión de dióxido de carbono en el aire exhalado ($EtCO_2$).

Los resultados validan la OMO, pero dependen de los factores de las funciones objetivo. Presentan buenos resultados para los modelos de impulsos finitos en términos de índices, pero los rendimientos son mejores en los modelos regresivos.

Palabras Claves: *Autorregulación cerebral, ARI, mfARI, optimización multi-objetivo, índice de calidad, FIR, NFIR, ARX, NARX, máquinas de vectores soporte, frente de Pareto, $EtCO_2$.*

ABSTRACT

Cerebral autoregulation is a concept that doesn't have a standard way to be measured, therefore, different techniques have been developed to model this behaviour. The goal is to obtain distinct models, select one that captures the autoregulation phenomenon and quantify its value. In order to do this the *Auto-Regulation Index* (ARI) and *model free Auto-Regulation Index* (mfARI) are used, having this last lower variability between subjects in equity of conditions. Recently, there has been an improvement implementation in the selection stage, that automates the process basing in some signal features. But this strategy evaluates only models with the highest correlation, forcing to an exhaustive search.

The objective is to perform an analysis with multi-objective optimization (OMO), and compare it with the actual paradigm using ARI, mfARI and a quality index based on the difference between the obtained indexes and the original signals. With OMO techniques it's posible to narrow the sample space with results significantly equal to those of the standard method.

Multivariate models of the *finite impulse response* (FIR) and *auto-regressive with exogenous inputs* (ARX) types were used, both of the lineal and no lineal type (NFIR and NARX), as structures for the learning method of the support vector machines. The data corresponds to 16 subjects from whom *Arterial blood pressure (ABP)*, Cerebral Blood Flow Velocity (CBFV) and end tidal carbón dioxide arterial pressure ($EtCO_2$) was obtained.

The results validates the optimization solution, but it depends on the factors used in the objective functions. Besides it shows good results for the finite impulse learnings in terms of ARI, mfARI and quality indexes, but the performance are better in the regressive models.

Keywords: *Cerebral autorregulation, ARI, mfARI, multi-objective optimization, quality index, FIR, NFIR, ARX, NARX, support vector machines, Pareto front, $EtCO_2$.*

GLOSARIO

AC	Autorregulación de la presión sanguínea a nivel cerebral.
AR	Sigla de autorregulación.
ARI	Autoregulatory Index. Índice de autorregulación, definido por Aaslid y Tiecks, los cuales estipulan 10 niveles para la medición de la autorregulación, con valores del 0 al 9, siendo 0 ausencia total de autorregulación y 9 autorregulación perfecta. Con la finalidad de generar mayor precisión las curvas de estos valores fueron interpoladas para obtener 91 curvas.
Butterworth	Filtro utilizado para suavizar el escalón de presión. En la autorregulación se utiliza para suavizar el escalón negativo que se mete en el modelo dependiendo del muestreo que se necesite.
CC	Coeficiente de correlación. Métrica utilizada para evaluar el rendimiento de un modelo.
CO ₂	Referencia al uso de dióxido de carbono en los entrenamientos para modificar el comportamiento autorregulatorio. También se usa para definir el retardo de dióxido de carbono.
Confianza	Proporción de ocurrencias de un conjunto de ítemes en un set de datos, sobre la ocurrencia de uno de ellos (soporte).
<i>EtCO₂</i>	<i>End-tidal CO₂</i> . Es utilizado como una medida para determinar la cantidad CO ₂ aspirado al final de la espiración.
Finapress	Instrumento no invasivo que permite registrar la presión sanguínea arterial, con una alta resolución temporal.
FSC	Flujo sanguíneo cerebral. Corresponde al flujo de sangre en los vasos cerebrales.
<i>grid</i>	Tipo de algoritmo de búsqueda que consiste en hacer un barrido completo, considerando todas las posibilidades dadas por la combinatoria de los factores que determinan la búsqueda.
Hipercapnia	Estado de salud que designa la presencia de un exceso de CO ₂ en la sangre producida por la inhalación en un ambiente rico en dióxido de carbono.
Hiperparámetro	Parámetros específicos de las <i>Support Vector Machines</i> .

Manguito	Instrumento que permite obstruir la presión sanguínea, colocándolo en el brazo o la pierna, su medida está en [mm Hg]. En los estudios de autorregulación corresponde a una maniobra de tipo no invasiva, en donde se utiliza un manguito de muslos con la finalidad de provocar una caída abrupta de la presión sanguínea.
mfARI	<i>Model-Free Auto-regulation Index</i> . Índice autorregulatorio, definido por Chacón, Jara y Panerai. Se utiliza para caracterizar numéricamente la autorregulación cerebral.
Normocapnia	Estado de salud que designa la presencia normal de CO ₂ en la sangre.
OMO	Optimización Multi-Objetivo. Técnica de los métodos de optimización enfocada en utilizar múltiples funciones objetivo a modo de encontrar un conjunto solución homogéneo que presente rendimientos iguales.
PAM	Presión sanguínea arterial media.
Pareto	Referencia al frente de Pareto, el cual considera un conjunto de elementos óptimos dadas ciertas funciones objetivos. Su característica es la maximización del beneficio de los factores sin la decremento de los otros.
Parsimonia	Postulado utilizado en el principio de la navaja de Occam que hace referencia a la búsqueda de simplicidad de la hipótesis, indicando que no debe hacerse con más lo que es posible realizar con menos. En otras palabras es la búsqueda de un máximo de variabilidad en un conjunto de elementos, considerando un mínimo de componentes posibles.
PPC	Presión de perfusión cerebral, corresponde a la diferencia entre la PAM y la PIC.
Soporte	Proporción de transacciones presentes en un <i>set</i> de datos que contiene cierto conjunto específico de ítems.
SVM	Support Vector Machine, en español máquinas de vectores soporte. Corresponde a un algoritmo de aprendizaje automático del tipo supervisado para modelar sistemas, su base se sustenta en la teoría de aprendizaje estadístico, son utilizadas para clasificación (SVC) y regresión (SVR).
SVR	Support Vector Regression, en español regresión mediante máquinas de vectores soporte.
Ultrasonido Doppler	Instrumento que entrega información sobre la velocidad y dirección del flujo para los vasos sanguíneos. En la autorregulación es usado para medir la VFSC, a través de la ventana temporal, en donde se encuentra la arteria cerebral media.
VFSC	Velocidad de flujo sanguíneo cerebral, corresponde a la salida de los modelos.

TABLA DE CONTENIDOS

CAPÍTULO 1. INTRODUCCIÓN	1
1.1. ANTECEDENTES Y MOTIVACIÓN.....	1
1.2. DESCRIPCIÓN DEL PROBLEMA	4
1.3. SOLUCIÓN PROPUESTA	4
1.4. OBJETIVOS	5
1.4.1. Objetivo general.....	5
1.4.2. Objetivos específicos.....	5
1.4.3. Alcances y limitaciones de la investigación.....	6
1.5. METODOLOGÍA Y HERRAMIENTAS UTILIZADAS	6
1.6. ORGANIZACIÓN DEL DOCUMENTO.....	8
CAPÍTULO 2. PRESENTACIÓN DEL PROBLEMA.....	9
2.1. AUTORREGULACIÓN CEREBRAL	9
2.2. ESTADO DEL ARTE	9
2.3. FUNDAMENTOS TEÓRICOS.....	12
2.3.1. SISTEMAS DINÁMICOS	12
2.3.2. MÁQUINAS DE VECTORES SOPORTE	14
Orígenes.....	14
Regresión lineal en las máquinas de vectores soporte	15
Formulación dual de la SVR	17
2.3.3. OPTIMIZACIÓN	19
Programación lineal	19
Optimización multi-objetivo	21
CAPÍTULO 3. MATERIALES Y MÉTODOS.....	24
3.1. SUJETOS Y MEDICIONES	24
3.2. PREPROCESAMIENTO DE DATOS.....	25
3.3. ESTRATEGIA DE MODELAMIENTO	26
3.3.1. Estructura de los modelos	26
3.3.2. Validación de los modelos	27
3.3.3. Selección de los parámetros	27
3.3.4. Algoritmo de Optimización multi-objetivo	28
3.4. Reglas de asociación	31
3.5. CRITERIOS DE EVALUACIÓN	32
Estadísticos	32
3.5.1. Coeficiente de correlación	32
3.5.2. Test de Shapiro-Wilk	33
3.5.3. T-test.....	34

3.5.4.	Respuesta al escalón de presión	34
3.5.5.	Filtro avanzado	36
3.5.6.	Índices autorregulatorios	36
3.5.7.	Análisis de Varianza de 3 vías.....	39
3.5.8.	Variables de estudio	40
	Correlación	40
	Complejidad	41
	Costo	41
	Nu.....	42
	Vectores soporte	42
3.5.9.	CALIDAD DEL MODELO.....	43
	CAPÍTULO 4. RESULTADOS	45
4.1.	ANÁLISIS COSTO LINEAL – EXPONENCIAL	45
4.2.	EVALUACIÓN DE OPTIMIZACIÓN MULTI-OBJETIVO	45
4.2.1.	Comportamiento del costo ante la calidad	47
4.3.	FRENTE DE PARETO	50
4.3.1.	Validación del Frente de Pareto respecto a índices ARI-mfARI.....	50
4.3.2.	Análisis de la calidad en frente de Pareto	50
4.3.3.	Aplicación de las reglas de asociación	52
4.4.	EFICIENCIA DE LOS MODELOS.....	56
4.5.	ÍNDICES AUTORREGULATORIOS DE LOS MODELOS	56
	CAPÍTULO 5. DISCUSIÓN	58
5.1.	ANÁLISIS CONTRASTE EXPONENCIAL – LINEAL.....	58
5.2.	ANÁLISIS PUNTAJES DEL FILTRO AVANZADO	58
5.3.	ANÁLISIS DEL FRENTE DE PARETO.....	59
5.4.	ANÁLISIS DE LA CALIDAD PARETO – FILTRO AVANZADO	61
5.5.	ANÁLISIS DE LA EFICIENCIA DEL FRENTE DE PARETO	62
5.6.	ANÁLISIS DE LOS ÍNDICES AUTORREGULATORIOS.....	63
	CAPÍTULO 6. CONCLUSIONES.....	65

ÍNDICE DE TABLAS

TABLA 2-1: Parámetros utilizados en el Modelo Aaslid-Tiecks	13
TABLA 2-2: Funciones Kernel de las SVM.	19
TABLA 3-1: Retardos utilizados en las estructuras de los modelos e hiperparámetros utilizados para el estudio de los modelos de entrenamiento.....	28
TABLA 3-2: Objetivos de la optimización multi-objetivo	29
TABLA 3-3: Discretización de las variables utilizadas en la optimización.	32
TABLA 3-4: Categorización de la Calidad.	32
TABLA 3-5: Factores de complejidad por modelo..	41
TABLA 3-6: Valores reales originales ARI y mfARI para los individuos del estudio.	43
TABLA 4-1: Resultados de test Shapiro – Wilk para los 2 tipos de costos analizados.	45
TABLA 4-2: Resultados de t – test mostrando que los conjuntos son significativamente iguales	45
TABLA 4-3: Resultados de contraste Pareto-Dominado en ANOVA de 3 vías para índices de calidad mfARI.	50
TABLA 4-4: Combinaciones posibles de factores para el frente de Pareto con sus respectivos promedios de calidad para cada método de aprendizaje.	51
TABLA 4-5: Calidad máxima y mínima para cada modelo de aprendizaje con sus respectivos factores del frente de Pareto.	52
TABLA 4-6: Variación en términos de calidad al cambiar los factores del frente de Pareto.	52
TABLA 4-7: Resultados de contraste Pareto-Dominado en ANOVA de 3 vías para índices de calidad mfARI en Pareto de 4 o menos factores.	52
TABLA 4-8: Categorías utilizadas para la calidad de las señales.	53
TABLA 4-9: Reglas de asociación para modelo de aprendizaje FIR con soporte = 0,25 y confianza = 0,1.	53
TABLA 4-10: Reglas de asociación para modelo de aprendizaje ARX con soporte = 0,25 y confianza = 0,1.	53
TABLA 4-11: Reglas de asociación para modelo de aprendizaje NFIR con soporte = 0,25 y confianza = 0,1.	53
TABLA 4-12: Reglas de asociación para modelo de aprendizaje NARX con soporte = 0,25 y confianza = 0,1.	54
TABLA 4-13: Resultado de test ANOVA de 3 vías para validez del conjunto frente de Pareto. ...	54
TABLA 4-14: Mejora de la calidad al cambiar foco del frente de Pareto.	54
TABLA 4-15: Índices de calidad para frente de Pareto y estudio de filtro avanzado.	55
TABLA 4-16: Presencia de modelo escogido a través del filtro avanzado en frente de Pareto. .	55
TABLA 4-17: Eficiencia promedio modelos	56
TABLA 4-18: Valores promedios de los índices de autorregulación.	56
TABLA 4-19: Resultados de test ANOVA de 3 vías para filtro avanzado y frente de Pareto	57
TABLA A-1: Índices autorregulatorios ARI promediados por modelo de aprendizaje, obtenidos mediante la optimización multi-objetivo.	74
TABLA A-2: Índices autorregulatorios mfARI promediados por modelo de aprendizaje, obtenidos mediante la optimización multi-objetivo.	74
TABLA A-3: Índices autorregulatorios ARI por modelo de aprendizaje, obtenidos por el filtro avanzado.	75

TABLA A-4: Índices autorregulatorios mfARI por modelo de aprendizaje, obtenidos por el filtro avanzado.	75
TABLA B-1: Promedios de las calidades de los individuos por método de aprendizaje para el frente de Pareto.	76
TABLA B-2: Promedio de las calidades de los individuos por método de aprendizaje para el filtro avanzado.	76
TABLA C-1: Reglas de Asociación para el subfrente de Pareto en aprendizaje FIR.	77
TABLA C-2: Reglas de Asociación para el subfrente de Pareto en aprendizaje ARX.	77
TABLA C-3: Reglas de Asociación para el subfrente de Pareto en aprendizaje NFIR.	79
TABLA C-4: Reglas de Asociación para el subfrente de Pareto en aprendizaje NARX.	80
TABLA D-1: Modelos seleccionados FIR.	81
TABLA D-2: Modelos seleccionados ARX.	81
TABLA D-3: Modelos seleccionados NFIR.	82
TABLA D-4: Modelos seleccionados NARX.	82

ÍNDICE DE FIGURAS

FIGURA 2-1: Gráficos de las funciones de pérdida (a) Cuadrática, (b) Laplaciana, (c) Huber y (d) ϵ -insensitiva.....	16
FIGURA 2-2: Ajuste de margen suave de pérdida para una SVR lineal.....	17
FIGURA 2-3: Problema de PL para la función objetivo $z=4x+3y$	21
FIGURA 2-4: El punto A contempla a una solución factible la cual es dominante respecto a los puntos B - F ya que posee un valor mínimo para f_1 ante ambos casos y un valor igual o menor para f_2 . Los puntos C - D dominan a A – B – F por las mismas características.	22
FIGURA 2-5: Conjunto de soluciones factibles C, donde la línea sobresaltada corresponde al conjunto dominante.	23
FIGURA 3-1: Estructura general del modelo FIR.....	26
FIGURA 3-2: Estructura general del modelo NFIR.....	26
FIGURA 3-3: Estructura general del modelo ARX.....	27
FIGURA 3-4: Estructura general del modelo NARX.....	27
FIGURA 3-5: Pseudocódigo de la implementación del frente de Pareto.	29
FIGURA 3-6: Árbol de navegación para obtener los distintos frentes de Pareto.	30
FIGURA 3-7: Frente de Pareto (puntos azules) dominando a los modelos (puntos rojos) de menor correlación y mayor cantidad de retardos.	30
FIGURA 3-8: Características de filtro visual básico para la selección de señal.	35
FIGURA 3-9: 91 curvas de autorregulación para variación de modelo Aaslid-Tiecks modificado.	38
FIGURA 3-10: Señal de respuesta a escalón introducido indicando las variables utilizadas en mfARI.	39
FIGURA 3-11: Señal real (azul) y señal predicha (rojo) con una correlación de 0.762.	41
FIGURA 3-12: SVM con un modelo mal clasificado (triángulo), esta holgura es permitida por el factor Nu.....	42
FIGURA 3-13: Separación dada por los vectores de soporte ubicados en la línea punteada que corresponde al margen del hiperplano.	43
FIGURA 4-1: Análisis gráfico del puntaje obtenido por el filtro avanzado versus la Correlación.....	46
FIGURA 4-2: Frente de Pareto de la gráfica “Retardos v/s Correlación” para un modelo FIR..	47
FIGURA 4-3: Gráfica de 3 dimensiones (Correlación-Costo Exponencial-Calidad mfARI) para todos los sujetos.	48
FIGURA 4-4: Gráfica de 3 dimensiones (NU-Costo Exponencial-Calidad mfARI) para todos los sujetos.....	48
FIGURA 4-5: Gráfica de 3 dimensiones (Retardos-Costo Exponencial-Calidad mfARI) para todos los sujetos.	49
FIGURA 4-6: Gráfica de 3 dimensiones (VS-Costo Exponencial-Calidad mfARI) para todos los sujetos.....	49

CAPÍTULO 1. INTRODUCCIÓN

El presente capítulo de este trabajo consta del episodio introductorio en el que se explican los antecedentes de la materia de estudio y las características que sirvieron de motivación para realizar este trabajo, seguidos de la descripción detallada de la problemática, un planteamiento de la solución propuesta (con sus propósitos, limitaciones y alcances). Luego se explican los objetivos generales y específicos del trabajo y la metodología utilizada en conjunto con las herramientas que fueron necesarias para alcanzar los objetivos. Finalmente se presenta brevemente la estructura del documento.

1.1. ANTECEDENTES Y MOTIVACIÓN

En el campo de la medicina existen variadas áreas de las cuales aún no existe completo conocimiento, áreas que han sido abordadas desde distintos puntos de vista pero dada su complejidad no ha sido posible entender su total funcionamiento. Un área de interés es el cerebro, esta caja negra que funciona a un ritmo diferente del resto del cuerpo.

Esta parte del cuerpo humano funciona como elemento procesador y coordinador de todas las partes restantes. Su importancia es total ya que es uno de los elementos fundamentales para poder realizar las actividades diarias. Su funcionamiento requiere energía, la cual es otorgada por la sangre que recorre el lecho vascular cerebral. Este último posee características que permiten que la sangre se irrigue a diferentes áreas gracias a la presión de perfusión cerebral (PPC).

Ante cualquier cambio de presión los vasos sanguíneos se dilatan y contraen regulando el paso del flujo de sangre, variando la velocidad del flujo sanguíneo cerebral (VFSC). Estas variaciones de flujo sanguíneo protegen al cerebro, ya que el cerebro posee una presión sanguínea arterial completamente diferente a la del resto del cuerpo. La autorregulación cerebral es la habilidad del cerebro para mantener un flujo constante de sangre a pesar de los cambios en la PPC (Muñoz, 2009).

Esto constituye el mejor mecanismo de defensa que posee el cerebro ante cualquier tipo de lesión o trauma (Lang, Mehdorn, Dorsch, & Czosnyka, 2002). Estudios previos han demostrado que cuando existe un deterioro del mecanismo autorregulatorio el pronóstico del paciente se ve afectado (Czosnyka, Smielewski, Piechnik, Steiner, & Pickard, 2001). Por otro lado aprender el funcionamiento de esta autorregulación permitiría realizar pronósticos sobre individuos, evaluar diagnósticos relacionados y guiar el tratamiento (Panerai, James, & Potter, 1997).

A través de los estudios y la literatura se ha definido índices para evaluar la autorregulación, siendo los más relevantes para este estudio el *auto regulation index* (ARI) y el *model free auto regulation index* (mfARI). El ARI corresponde al modelamiento de una ecuación diferencial de 2° orden, mientras que el mfARI no impone ningún modelo específico.

El índice que se utilice para evaluar la autorregulación no es irrelevante ya que existen diferencias. Entre estos sistemas de medida se ha demostrado que el mfARI presenta un nivel de robustez mayor que el ARI (Chacón, Jara, & B. Panerai, 2014). Para el caso de variaciones espontáneas de presión se requiere modelar primero y luego medir los índices.

El estudio realizado por Burgos (2014) constó del desarrollo de un entrenamiento muestral de modelos dinámicos con máquinas de vectores soporte, pero bajo un grupo de individuos diferenciado por su cantidad de CO_2 en la sangre (Hipercapnia, Normocapnia), obteniendo resultados de gran interés, pero sin denotar qué índice caracteriza mejor a los individuos.

Como se puede observar se han realizado variados estudios y por lo tanto un estándar único para evaluar la AR en cualquier tipo de paciente no existe. Los análisis poseen diferentes criterios y métodos (Panerai, James, & Potter, 1997) por lo cual han sido clasificados mediante el tipo de estudio y, conjuntamente, en diferentes grupos de sujetos, esto conlleva a soluciones específicas para individuos con características puntuales.

Inicialmente la autorregulación cerebral se estudió de forma estática, esto es, la forma de medir la presión se realizaba en instantes de tiempo regulares. Estos puntos discretos en el tiempo reflejaban un comportamiento que no representaba del todo a la señal, ya que existían vacíos en las mediciones, calculando un promedio de los puntos de presión en el tiempo que duraba la medida. Pero en la actualidad se prefiere el modo dinámico en que se mide la presión sanguínea arterial media (PAM) y la VFSC durante una perturbación de presión sanguínea arterial (Aaslid, Lindegaard, Sorteberg, & Nornes, 1989).

Para esto se utilizan las mediciones de la PAM y la VFSC, las cuales deben ser continuas en el tiempo de forma que se obtenga un conjunto de datos representativos. Esto se consigue mediante herramientas modernas que permiten obtener la información de manera precisa. Para medir la PAM se ocupa un **Finómetro** y para la VFSC el Doppler Transcraneal. Ambas herramientas toman aproximadamente más de mil muestras por segundo, siendo así prácticamente una medición continua y entregando una precisión aceptable para los análisis. Por otra parte, el cambio de presión no invasivo se realiza con el uso de unos manguitos colocados a la altura de los muslos, **que impiden el flujo produciendo un aumento de presión** sanguínea arterial y son liberados después de un periodo de tiempo. Estos métodos y herramientas se explican en su correspondiente capítulo (sección 3.1).

La ventaja de obtener estas mediciones es que, siguiendo una serie de pasos establecidos, se pueden obtener índices que reflejen el comportamiento de la AR. El índice definido por la ciencia para la autorregulación dinámica es el ARI, este índice corresponde al

cambio en la resistencia cerebro vascular por segundo en relación con el cambio en la PAM (Tiecks, Lam, Aaslid, & Newell, 1995). Su medición se hace con señales de 30 segundos después de una maniobra dinámica, donde basado en la presión sanguínea arterial, se calcula una curva de la velocidad de flujo sanguíneo cerebral hipotética sin autorregulación. Se asume que esta curva seguiría pasivamente el curso de la presión sanguínea arterial, es decir que la variación porcentual de la velocidad de flujo sanguíneo cerebral sería la misma que la de la presión sanguínea cerebral (con un error cuadrático medio muy bajo). Considerando esto se puede categorizar la curva en 10 niveles (0 al 9), cada una con un mayor grado de capacidad autorregulatoria, buscando la curva que mejor se ajuste a la VFSC verdadera (Tiecks, Lam, Aaslid, & Newell, 1995). A pesar de poseer gran aceptación en la comunidad científica, tiene una gran deficiencia, y es que si el ARI es calculado sobre un mismo individuo, presenta gran varianza en los resultados (Mahony, Panerai, Deverson, Hayes, & Evans, 2000). Por otra parte cabe mencionar que presenta gran cantidad de falsos positivos.

Los estudios han permitido que se encuentre mejoras dentro de la medición, a modo de disminuir esta varianza por individuo. Nuevas técnicas (Panerai, Eames, & Potter, 2003) que incluyen regresión lineal y no lineal han permitido encontrar valores más acertados y consistentes, lo que motiva a trabajar utilizando elementos de mayor precisión.

Pero realizar esta modalidad dinámica no siempre es posible, ya que dependiendo del estado de salud el individuo podría resultar peligroso realizar cambios bruscos de presión. Para esto existe una alternativa más cómoda, la cual sería utilizar simplemente las variaciones espontáneas de presión, y caracterizar su comportamiento a la respuesta autorregulatoria para obtener el ARI. Bajo este enfoque no se ha encontrado buenos resultados al momento de obtener el ARI desde variaciones espontáneas de presión (Panerai, James, & Potter, 1997). Estudios posteriores han demostrado que si se entrena un modelo con las variaciones espontáneas de presión y a ese modelo se le pasa un escalón, también se pueden encontrar resultados válidos para el fenómeno (Chacón, Nuñez, Henríquez, & Panerai, 2008).

Así, se ha hecho varios modelos tales como respuesta de impulso finito (FIR), respuesta de impulso finito no lineal (NFIR), auto-regresivo con variable exógena (ARX), auto regresivo no lineal con variable exógena (NARX); modelos univariados y multivariados, con redes neuronales artificiales y máquinas de vectores soporte (SVM). Estudios previos indican que la mejor opción es utilizar las SVM ya que presentan mejores resultados en términos de precisión y cálculo de la reactividad de los vasos sanguíneos cerebrales a la presión arterial de CO_2 ($EtCO_2$), presentan menor varianza y un muy bajo error cuadrático medio en la línea base de presión (Chacón M. , 2009). Es en este contexto que aparecen dificultades, porque para conseguir un buen modelo, los algoritmos de entrenamiento se prueban con muchas combinaciones de hiperparámetros, generando cientos de miles de modelos por individuo. De estos se debe elegir uno que haya capturado la relación PAM/VFSC sin estar sobreentrenado. En general esta selección se ha hecho de forma manual por el investigador.

1.2. DESCRIPCIÓN DEL PROBLEMA

En un estudio reciente (Miranda, 2016) se presentó el entrenamiento de modelos dinámicos con máquinas de vectores soporte utilizando diferentes combinaciones de los parámetros de entrada sobre pacientes con Normocapnia e Hipercapnia, aplicando a los resultados un nuevo filtro que es una mejora del método clásico (el cual consta de una simple inspección visual). Este filtro permite asignar valores numéricos a comportamientos esperados en la señal de la respuesta autorregulatoria, seleccionando así 100 posibles modelos, de los cuales se escoge el de más alta correlación.

Pero este es solo un enfoque de muchas posibilidades que se puede aplicar. Una nueva hipótesis implica la utilización de técnicas de optimización para así obtener una serie de modelos óptimos y a la vez poder realizar un análisis sobre los factores de cada modelo. El poder obtener resultados significativos implicaría acotar inicialmente el espacio muestral sobre el que se realiza el estudio de la autorregulación, lo cual es de suma importancia, ya que permitiría obtener resultados igual de precisos de una forma más rápida y eficiente, siendo esto de vital importancia al momento de diagnosticar y tratar a un individuo con algún tipo de afección cerebral.

Se necesita de un método automático de mayor eficiencia para seleccionar los mejores modelos, considerando diferentes criterios de aceptación como calidad predictiva (es decir la precisión de los índices obtenidos respecto a los índices reales obtenidos de los sujetos), **parsimonia**, (simplicidad que presenta el modelo) y verosimilitud fisiológica (que la respuesta al escalón se presente dentro de los rangos normales del comportamiento humano).

Varios estudios previos (Bello, 2007; Ruz, 2009; Varas, 2013) realizan el entrenamiento de modelos con las medidas obtenidas de los individuos y, posteriormente realizan un filtro básico que acota la señal de respuesta de flujo sanguíneo cerebral a ciertos rangos respecto a los tiempos y la amplitud de la señal.

Dadas las características de la solución utilizada, cabe notar que existen variantes las cuales también podrían tener valor para la problemática. Nuevos enfoques de optimización mezclados con técnicas que permitan discriminar los resultados, sumados con análisis estadísticos y técnicas comparativas, abren un gran gama de posibles desarrollos. Por lo tanto se llega a la pregunta primordial de esta investigación ¿Sería posible encontrar otra forma de realizar el desarrollo del experimento? ¿Será esta forma la más efectiva para obtener un modelo representativo de la autorregulación? ¿Cómo se podría tomar una mejor decisión del modelo a utilizar?

1.3. SOLUCIÓN PROPUESTA

La solución consta en evaluar la información que se tiene para seleccionar un modelo representativo para los individuos en estudio, con la intención de proponer guías que permitan reducir el espacio de búsqueda.

Con los datos de los individuos seleccionados se desea realizar el entrenamiento en cuatro tipos de modelos de aprendizaje:

- *Linear auto-regressive with exogenous variable* (ARX).
- *Non-linear auto-regressive with exogenous variable* (NARX).
- *Finite impulse response* (FIR).
- *Non-linear finite impulse response* (NFIR).

Sobre cada espacio muestral del resultado de los entrenamientos se aplica un escalón negativo y de la respuesta a los modelos entrenados se obtienen los índices de autorregulación ARI y mfARI con su posterior análisis estadístico para comparar su representatividad y significancia. Luego se debe aplicar un algoritmo de selección de modelos basado en la optimalidad de los factores, en función de disminuir la complejidad de estos.

Una vez obtenidos estos factores se da el enfoque del principio de parsimonia, para definir diferentes funciones objetivo que representen simplicidad, correlación y respuesta al escalón. Esta es la base con que se desea optimizar la solución. Posteriormente, se evalúa si el conjunto de modelos óptimos es más representativo o significativo que el óptimo simple dado por la función objetivo definida en el estudio asociado con el que se desea comparar (Miranda, 2016).

El propósito de la solución es determinar si existe alguna diferencia influyente en la evaluación del resultado óptimo de la función objetivo, ya que dado el enfoque de la optimización multi-objetivo (OMO), es posible que se determine qué características conjuntas son más determinantes ante la muestra de datos dados por los entrenamientos. Si se llegase a observar que existe una diferencia muy significativa sobre los resultados de la(s) función(es) objetivo entonces se debe determinar la relevancia de cada uno de los objetivos definidos, denotando variables de interés para los estudios de autorregulación cerebral.

Si esto ocurre, es factible obtener resultados eficientes de una forma más rápida, lo que podría acelerar el diagnóstico y tratamiento de los pacientes.

1.4. OBJETIVOS

1.4.1. Objetivo general

Utilizar la OMO para **determinar la información más** relevante para seleccionar los modelos biológicos que representen de mejor manera el comportamiento real de la autorregulación cerebral de un individuo.

1.4.2. Objetivos específicos

Como objetivos específicos se tiene:

- Diseñar el método para seleccionar los modelos en base al criterio de la OMO.

- Diseñar el experimento utilizando los modelos de aprendizaje y las técnicas de máquinas de vectores soporte
- Realizar los experimentos utilizando la estrategia diseñada de la OMO y las SVM.
- Obtener los índices y evaluar las variables utilizadas para medir su efecto e impacto en la calidad y precisión de las señales biológicas.
- Comparar los enfoques de OMO y filtro avanzado de señal basándose en la calidad de las señales biológicas.
- Analizar los resultados obtenidos que permitan validar la efectividad del método y realizar las conclusiones pertinentes.

1.4.3. Alcances y limitaciones de la investigación

Los datos de los pacientes corresponden a individuos que no presentan ningún historial de enfermedad. El estudio fue aprobado por el *Comité de Ética de Investigación de Leicestershire*, y los consentimientos fueron obtenidos para cada voluntario del estudio.

A cada individuo se le midieron las variaciones espontáneas de presión. Por otra parte, no padecen ningún problema cardíaco o cerebral ni toman algún medicamento que afecten los sistemas involucrados, o que alteren las pruebas.

Los resultados obtenidos del aprendizaje deben ser filtrados mediante una inspección estándar de medidas fisiológicas, para luego calcular sus índices ARI y mfARI y, posteriormente, ser evaluados mediante las técnicas de OMO. Finalmente serán comparados los resultados con los resultados obtenidos por los puntajes del filtro avanzado de Miranda (2016).

1.5. METODOLOGÍA Y HERRAMIENTAS UTILIZADAS

Este proyecto corresponde a un modelamiento que requiere métodos de aprendizaje supervisado basado en sistemas dinámicos, por lo tanto se realiza una conjetura y se entrena en espera de un comportamiento o salida. Es por este motivo que se ha decidido utilizar el método científico como metodología, y así lograr obtener la validez adecuada para el análisis comparativo entre los distintos modelos e índices.

Se pretende utilizar las siguientes etapas del método científico:

- **Percepción del fenómeno:** Utilización de los sentidos para observar un fenómeno determinado, y analizar las cualidades del problema de forma adecuada.
- **Identificación y definición del problema:** Consiste en elaborar preguntas, que permitan llegar a alguna explicación lógica de un fenómeno con mayor precisión. El problema debe quedar establecido con claridad, estudiando las áreas del

cálculo de la autorregulación y todo lo que se necesita para resolver la problemática.

- **Proposición de la hipótesis:** Corresponde a lo que se intenta comprobar en base a la pregunta general obtenida de la serie de preguntas de la etapa anterior. Es la propuesta a la que se apunta para validar (o invalidar) el estudio. Para el caso puntual de este estudio, la hipótesis corresponde a que el conjunto acotado de modelos dado por la OMO es suficiente como conjunto representativo para obtener resultados válidos.
- **Diseñar experimentos:** Se describe los métodos y estrategias para lograr las condiciones de reproducción informática de los experimentos. En este caso se debe usar modelos FIR, NFIR, ARX y NARX.
- **Verificación de la hipótesis:** Se pone a prueba la hipótesis planteada, con ayuda de diseños experimentales. Se debe establecer una estrategia para asegurar las condiciones en las que se pueda reproducir el fenómeno y probar la hipótesis planteada.

Para el desarrollo de la recopilación de datos y los análisis se hace uso de todas las herramientas disponibles en el laboratorio de Ingeniería aplicada a la medicina y Biología del Departamento de Ingeniería Informática de la Universidad de Santiago de Chile, el cual cuenta con:

- Finómetro Finapres para medir la presión sanguínea de manera continua y no invasiva.
- Doppler Transcraneal, medidor del flujo sanguíneo cerebral para la arteria cerebral media derecha.
- Computador Intel P4 (1GB, 3GHz)
- Windows 7, sistema operativo para montar todo el *software* requerido.
- R versión 3.2.2 (2015), *software* estadístico para el entrenamiento de los datos y los análisis estadísticos. Paquetes: *e1070*, *effsize*, *ggplot2*, *normtest*, *plotly*, *scatterplot3d*, *arules*.
- Programa ARI y mfARI, *software* implementado en R que realiza el cálculo de los índices.
- Microsoft Office, *software* herramientas administrativas para crear informes, presentaciones y carta Gantt del proyecto.
- Notebook HP Envy (12GB, 2.5 GHz Core i7).

1.6. ORGANIZACIÓN DEL DOCUMENTO

En esta sección se describe la organización del presente trabajo, presentando de manera general el contenido de los capítulos que lo componen. En el capítulo 2, se presenta la problemática en la que se enfoca este estudio, el funcionamiento del sistema de autorregulación cerebral y la influencia de algunas señales sobre su comportamiento. También se muestra el estado del arte con respecto al modelamiento del sistema de autorregulación cerebral y las investigaciones realizadas con la incorporación de la presión intracraneal. Este capítulo se cierra con todos los fundamentos técnicos y teóricos que son la base sobre la que se establece el estudio, se presenta el conocimiento base necesario para la comprensión del contenido de este trabajo. Se realiza una descripción de los sistemas dinámicos y se revisa los distintos modelos utilizados en el estudio del sistema de AR cerebral. Se presenta una descripción del funcionamiento de las máquinas de vectores soporte. En el capítulo 3, denominado “Materiales y Métodos” se explica las herramientas y estrategias utilizadas para el modelamiento del sistema de autorregulación cerebral en el presente estudio. Se exponen las características de los pacientes involucrados, las mediciones que generaron las señales utilizadas en el modelamiento y la descripción de la estrategia de modelamiento, abarcando la estructura de los modelos, los criterios para su evaluación y la utilización de distintas métricas de eficiencia. En el capítulo 5 se muestra los resultados obtenidos del proceso de modelamiento para luego presentar en el capítulo 6, la discusión sobre los resultados obtenidos de esta investigación. En el último capítulo se detalla las conclusiones respecto a la investigación realizada, junto con la propuesta de trabajos futuros para continuar las investigaciones sobre el sistema de autorregulación cerebral y sus alcances. Finalmente, se presenta las referencias bibliográficas utilizadas en la elaboración del trabajo y los documentos anexos.

CAPÍTULO 2. PRESENTACIÓN DEL PROBLEMA

A continuación, se describe las características que conforman la base de la problemática del presente trabajo. Se explica el concepto de autorregulación cerebral (AC) y sus actuales interrogantes, seguido del estado del arte para los principales elementos claves del trabajo.

2.1. AUTORREGULACIÓN CEREBRAL

Como se mencionaba en el capítulo anterior, la AC es la habilidad del cuerpo humano para mantener el flujo sanguíneo en el cerebro de manera constante ante cambios de presión. De tal forma es igualmente importante realizar una medición objetiva de la misma, ya que la evaluación de la AC es de suma importancia para diagnosticar, monitorear o pronosticar enfermedades cerebrales (Panerai, 1998).

Las mediciones en la actualidad presentan diferentes enfoques, los cuales son escogidos dependiendo del estudio realizado. Estos enfoques poseen distintas características que varían bastante dependiendo el objetivo que se pretenda alcanzar. Es por esto que no existe una forma estándar de medición de AC y la variedad de los métodos de medición y sus criterios es extensa (Panerai, 1998).

La raíz de este problema recae en que la AR es más bien un concepto al cual se le intenta dar un comportamiento que permita modelar de manera objetiva los niveles de recuperación de flujo sanguíneo cerebral, más que una entidad físicamente medible (Panerai, 1998).

La AC se mueve dentro de un campo acotado de presión sanguínea dado por 50 mmHg y 150 mmHg. Si por algún motivo la presión sanguínea cerebral (PAM) sale de estos rangos el cerebro perdería su capacidad autorregulativa. Lo que sucede es que el lecho vascular cerebral posee un flujo autorregulado ya que el flujo sanguíneo cerebral se mantiene relativamente constante (Lassen, 1959).

La AR cumple un rol importante en la salud cerebral. El cerebro necesita constante oxígeno para el metabolismo celular, si los niveles de oxígeno no son los suficientes podría producirse una hipoxia cerebral (Horiuchi, y otros, 2016) y con ello podría derivar en muerte del tejido cerebral. Este mecanismo homeostático del cuerpo suministra la sangre necesaria para la demanda metabólica de las actividades que el ser humano realiza diariamente (Busija, 1993), o en situaciones de riesgo que incluyen condiciones críticas como los traumas encéfalo craneanos con resultados hemorrágicos o la hidrocefalia.

2.2. ESTADO DEL ARTE

Franck Tiecks *et al.* (1995) fueron pioneros de las nuevas metodologías de medición, ya que sus estudios se basaron en técnicas comparativas para así evidenciar las grandes diferencias

entre los métodos estáticos y los dinámicos. El enfoque de interés resultante que se produjo en ese punto fue impresionante. Se pudo descubrir que existía una respuesta continua la cual seguía un patrón único para todos los individuos que pudo ser caracterizado en un modelo de 10 niveles para clasificar la capacidad autorregulatoria del individuo.

Posteriormente fueron surgiendo adiciones al modelo de Tiecks, donde se debe remarcar los aportes de Panerai (1997), los cuales presentaron análisis comparativos de la mayoría de los métodos de evaluación existentes, además de entregar valiosos resultados al área de estudio basado en la evaluación de cambios espontáneos en la AC.

En la actualidad el estudio de la AC consiste principalmente en medir la PAM y la velocidad de flujo sanguíneo cerebral (VFSC) que entra por las arterias cerebrales. Con estas medidas se puede modelar un comportamiento utilizando técnicas de aprendizaje en variados enfoques.

Uno de los enfoques aceptados y utilizados en los estudios del Departamento de Ingeniería Informática de la Universidad de Santiago de Chile, es utilizar técnicas de aprendizaje supervisado que permitan obtener modelos representativos de los sujetos, tales como las máquinas de vectores soporte (SVM). Las SVM entregan modelos obtenidos mediante una regresión, la que permite realizar una estimación de la VFSC, capturando el fenómeno de la AC.

La aplicación de metodologías basadas en regresión multivariada con aplicaciones en clasificadores se puede visualizar en el trabajo de Chacón (Chacón, Araya, & B. Panerai, 2011), que establece una adición al modelamiento basado en técnicas de minería de datos para obtener aún más robustez en el modelo original de Tiecks, y que puede ser usado con el paciente en estado de reposo con variaciones espontáneas de presión.

Con el aprendizaje realizado se puede filtrar los modelos para obtener los que mejor representen el comportamiento de la autorregulación cerebral. Este filtro en primera instancia consta de 3 reglas que son prácticamente visuales, ya que significa simplemente ver la señal y cerciorarse que la señal esté dentro de ciertos rangos definidos de tiempo y presión. Pero un estudio reciente define un nuevo algoritmo complementario que se basa en puntajes. Además de utilizar los criterios previamente mencionados como filtro, añade 4 nuevos criterios fijándose en las características de la señal:

- Se evalúa si la caída de la señal es muy abrupta y si posee *spikes* que produzcan ruido en la señal. Enfocándose en estas características se penaliza.
- Después de la subida de estabilización de la señal, se evalúa la segunda caída, enfocándose si ésta corresponde al 45% de la primera caída. Si es más que eso se comienza a penalizar.
- Se evalúa la sección de estabilización de la señal, enfocándose en la cantidad de oscilaciones y su amplitud.

- Se evalúa y penaliza fijándose en la tendencia final de la señal después de la estabilización (si se mantiene, crece o decrece).

Estas características ofrecen un nuevo enfoque al filtrar (Miranda, 2016). En primera instancia se realiza una búsqueda exhaustiva (*grid*) de los modelos mediante una combinatoria total de parámetros, con los filtros utilizados normalmente. Luego se realiza este nuevo filtro en base a nuevas reglas, que consisten principalmente en darle un valor definido por quien realiza el estudio a ciertos comportamientos observables en la señal. Estos valores permiten obtener modelos que entregan señales autorregulatorias que pueden ser producidas por un ser humano, siendo esto último de suma importancia ya que el uso del filtro escalón sobre los distintos modelos presenta casos donde se observa que la señal toma valores que no son válidos para los rangos normales de la raza humana.

Con los modelos seleccionados por el nuevo filtro se realiza la búsqueda de un valor óptimo basado en una función objetivo y sus respectivas restricciones, para definitivamente encontrar el mejor modelo del aprendizaje realizado. Hasta ahora, considerando los estudios existentes, el único factor que se ha usado para finalmente seleccionar un modelo, es la correlación en señales de validación distinta a la entrenada. Esto es un problema si se considera que existen casos donde los modelos de aprendizaje tienen a sobre-aprender el comportamiento entrenado.

Pero bajo este criterio es posible abordar nuevas formas de obtener el mejor modelo, ya que, la optimización depende puntualmente de la función objetivo, y ésta puede cambiar dependiendo del enfoque del estudio. Aquí es donde entra en juego la cantidad de características inherentes a la señal y la optimización multi-objetivo (OMO).

Esta última constituye una complejidad más alta que la optimización simple, ya que la función objetivo cambia los elementos de la función al dominio múltiple de los reales. Esto puede conllevar a conflictos ya que por lo general el favorecer un objetivo implica denigrar a otros, pero se puede utilizar el enfoque del principio de Pareto, el cual busca un equilibrio y de esa forma obtener lo mejor de un elemento sin desfavorecer al resto (Chaudhari, Dharaskar, & Thakare, 2010).

Los problemas de OMO son altamente usados en la actualidad, sobre todo en computación evolutiva, algunas aplicaciones son (Amarilla, Almeida, & Barán, 2004):

- Problemas de redes y enrutamiento de datos.
- Problemas de diseño de distribución de redes eléctricas.
- Planificación de centrales telefónicas.
- Problemas de recorridos y frecuencias de transporte público.
- Algoritmos genéticos y computación evolutiva.
- Problemas genéricos que impliquen variedad de factores, etc.

Siguiendo este enfoque se podría definir más de un modelo óptimo que representaría la señal con sus respuestas y análisis al estudio de la AC.

Finalmente se puede entender cómo la evolución respecto al estudio de la AC ha crecido exponencialmente, y cuán importantes han sido estos avances. Cabe hacer notar que aunque existe una infinidad más de estudios que acá no han sido mencionados, los trabajos mencionados recientemente corresponden a estudios relevantes para fines del proyecto propuesto.

2.3. FUNDAMENTOS TEÓRICOS

2.3.1. SISTEMAS DINÁMICOS

Los sistemas dinámicos son aquellos que consideran el espacio temporal para ordenar los datos, es decir, analizan la variable tiempo de forma continua, teniendo una cantidad de datos significativos y representativos, esto contrasta de forma correcta con los modelos estáticos que consideran la dimensión temporal como puntos fijos y discretos. Esto se traduce a que en un sistema las salidas dependen no solo de la variable t_i actual, sino que también de sus predecesoras t_{i-1}, t_{i-0}, \dots

A esta dimensión temporal se le llama serie de tiempo $x(t)$ y es justamente la considerada en los modelos dinámicos utilizados en este estudio, los cuales son lineales y no lineales. Para los estudios de autorregulación lineal se puede mencionar el modelo Aaslid-Tiecks con el índice de autorregulación (ARI) con PAM como entrada, para el caso de los no lineales destacan los modelos de Wiener Laguerre (Panerai, Dawson, & Potter, 1999a; Panerai, Deverson, Mahony, Hayes, & Evans, 1999b; Panerai, Dawson, Eames, & Potter, 2001), las redes Laguerre-Volterra (Mitsis, Zhang, Levine, & Marmarelis, 2002; 2006), las redes neuronales, (Muñoz, 2009; Panerai, Chacon, Pereira, & Evans, 2004; Chacón, Blanco, Panerai, & Evans, 2005), y máquinas de vectores soporte (Díaz, 2005; Araya, 2006; Bello, 2007).

Al ser la autorregulación cerebral un concepto no refinado, no existe un denominado “*gold standard*” (Panerai, 1998), por lo que cabe definir estándares de medición aceptados por la ciencia.

En Aaslid *et al.* (1989) se introdujo la maniobra de los manguitos para inducir respuestas del flujo sanguíneo cerebral y, más adelante, un modelo matemático para cuantificar la eficacia de la autorregulación dinámica (Tiecks, Lam, Aaslid, & Newell, 1995), el cual es descrito a continuación.

Modelo Aaslid-Tiecks (A-T)

La maniobra de manguitos consta de una caída de presión inducida por la oclusión sanguínea. Esta maniobra fue diseñada para establecer un modelo matemático que represente

el comportamiento de la autorregulación. El modelo se caracteriza por estados de segundo orden dados por las ecuaciones 2.1, 2.2, 2.3 y 2.4.

$$V(n) = V_0(1 + dP(n) - K \times x_2(n)) \quad (2.1)$$

$$x_1(n) = x_1(n-1) + \frac{dP(n-1) - x_2(n-1)}{f \times T} \quad (2.2)$$

$$x_2(n) = x_2(n-1) + \frac{x_1(n-1) - 2 \times D \times x_2(n-1)}{f \times T} \quad (2.3)$$

$$dP(n) = \frac{PAM(n) - P_0}{P_0 - PCC} \quad (2.4)$$

Con

- dP es el cambio normalizado de PAM en torno a la presión de control (P_0), considerando el efecto de la presión de cierre crítica (PCC).
- La V_0 es la velocidad de control en la arteria cerebral media.
- T es la constante de tiempo.
- D es el factor de amortiguamiento.
- K es la ganancia autorregulatoria dinámica.
- f es la frecuencia de muestreo.
- x_1 y x_2 son variables de estado que se asumen iguales a cero durante el periodo de control.

A partir de las señales reales de presión y con diez tripletas de valores para los parámetros D , K y T , se generan diez curvas teóricas que representan distintos niveles de comportamiento del sistema de AC expresadas en el ARI, que toma valores ordinales desde 0 (mala autorregulación) hasta 9 (buena autorregulación). Éstos se pueden ver en la tabla 2.1, con su respectivo nivel de ARI.

TABLA 2.3.1-1: Parámetros utilizados en el Modelo Aaslid-Tiecks. Fuente: Tiecks et al., (1995).

T	D	K	ARI
2.00	1.70	0.00	0
2.00	1.60	0.20	1
2.00	1.50	0.40	2
2.00	1.15	0.60	3
2.00	0.90	0.60	4
1.90	0.75	0.90	5
1.60	0.65	0.94	6
1.20	0.55	0.96	7
0.87	0.52	0.97	8
0.65	0.50	0.98	9

Cada una de las diez curvas teóricas se compara con la señal de VFSC real, asignando así a esta última el ARI correspondiente a la curva más ajustada (Tiecks, Lam, Aaslid, & Newell, 1995). El criterio de ajuste de curvas utilizado por Aaslid y Tiecks es el menor error estándar de la media de las diferencias entre la curva estimada y la curva real, cuya expresión se muestra en la ecuación 2.5, en donde V es la señal de flujo y n es el largo de la misma.

$$SE = \frac{1}{\sqrt{n}} \times \sqrt{\frac{\sum_{i=1}^n (\Delta V_i - \bar{V})^2}{(n-1)}} \quad (2.5)$$

Modelo Aaslid-Tiecks Decimal.

El modelo Aaslid-Tiecks decimal (Nuñez, 2003) corresponde a una variación del modelo recientemente descrito. La única diferencia es que corresponde a 91 niveles en vez de los 10 niveles ya definidos. Esta especificación de los niveles se logró simplemente realizando una interpolación de los 10 niveles originales.

2.3.2. MÁQUINAS DE VECTORES SOPORTE

Orígenes

El algoritmo de vectores soporte se presenta como una evolución generalizada del algoritmo *Generalized Portrait* (Vapnik & Lerner, 1963; Vapnik & Chervonenkis, 1971) la cual dio pie a la teoría VC (siglas iniciales de Vapnik & Chernovnenkis). Esta teoría se basa en métodos de aprendizaje estadístico y caracteriza las propiedades de las máquinas de aprendizaje, lo que permite que se pueda realizar una buena generalización a datos desconocidos (Smola & Schölkopf, 1998a).

Finalmente las SVM fueron desarrolladas por Vapnik y otros (Boser, Guyon, & Vapnik, 1992), donde su aplicabilidad se restringía a problemas de clasificación (*Support Vector Clasification*, SVC) para separar las clases a través de un hiperplano del mayor margen posible (Boser, Guyon, & Vapnik, 1992). Esto implica cierta rigidez del margen, lo que descarta a los problemas más complejos. Por esto, Cortes & Vapnik (1995) introdujeron el concepto de margen blando (*soft margin*) el cual flexibiliza el margen entendiendo el campo sobre el cual se podía aplicar las máquinas de vectores soporte.

De esta forma las máquinas de vectores soporte puede utilizarse como aprendizaje supervisado para clasificación y regresión, siendo este último caso utilizado en estudios de AC (Díaz, 2005; Araya, 2006; Bello, 2007; Burgos, 2014; Chacón, Araya, & B. Panerai, 2011; Chacón, Jara, & B. Panerai, 2014; Gajardo, 2014; Noh, 2014; Ruz, 2009) entregando buenos resultados.

Regresión lineal en las máquinas de vectores soporte

El concepto de regresión se aplica a las máquinas de vectores soporte de forma que se intenta obtener una aproximación lineal a partir de una serie de datos $(\vec{x}_1, y_1), (\vec{x}_2, y_2), (\vec{x}_3, y_3), \dots, (\vec{x}_n, y_n)$, donde \vec{x}_i es un vector de p dimensiones e y_i es un número real, con n el total de datos. La función 2.6 caracteriza el comportamiento a aproximar.

$$f(\vec{x}) = (\vec{w} \cdot \vec{x}) + b \quad (2.6)$$

Donde \vec{w} es un vector de dimensión p , $(\vec{w} \cdot \vec{x})$ el producto punto entre los vectores y b un número real. El objetivo es minimizar la d-norma de \vec{w} como se puede ver en la ecuación 2.7. Si la d-norma es igual a 2, entonces el problema es de optimización cuadrático convexo (Smola, 1996), dado por las siguientes restricciones de la ecuación 2.8.

Minimizar:
$$g(\vec{w}) = \frac{1}{2} \|\vec{w}\|^2 \quad (2.7)$$

Dado:
$$g(\vec{w}) = |y_i - (\vec{w} \cdot \vec{x}_i) + b| \leq \varepsilon \quad (2.8)$$

Para problemas de este tipo, el enfoque de la regresión asume que se podría encontrar una función que aproxime los datos con una precisión definida, pero esto no es siempre factible dado el ruido de los datos. Es por esto que en optimización se utiliza las variables de holgura que representan los márgenes de error. Estas variables se denominan ξ_i y ξ_i^* cuya relación con la precisión es establecida a través de las denominadas funciones de pérdida (Vapnik, 1995). Existen variadas funciones de pérdida aplicables a los problemas de regresión, siendo su único requisito que el problema sea convexo para asegurar la existencia de un óptimo único. En la figura 2-1 se observan las funciones de pérdida aplicadas a las máquinas de vectores soporte más usadas (Gunn, 1998).




FIGURA 2.3.2-1: Gráficos de las funciones de pérdida (a) Cuadrática, (b) Laplaciana, (c) Huber y (d) ε -insensitiva. Fuente: Gunn (1998).

Si se utiliza la función de pérdida ε - *insensitiva* el problema original se transforma en la ecuación 2.9.

Minimizar:

$$g(\vec{w}) = \frac{1}{2} \|\vec{w}\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) \quad (2.9)$$

Sujeto a:

$$\begin{aligned} y_i - (\vec{w} \cdot \vec{x}_i) - b &\leq \varepsilon + \xi_i \\ (\vec{w} \cdot \vec{x}_i) + b - y_i &\leq \varepsilon + \xi_i^* \\ \xi_i, \xi_i^* &\geq 0 \end{aligned}$$

La constante C es siempre positiva y determina el balance entre la influencia del error y la inclinación de la función f . En la figura 2-2 se puede apreciar el enfoque de la solución del problema de optimización, donde los puntos fuera de la vecindad ε penalizan aumentando los costos. Este problema de optimización disminuye su complejidad si se aborda mediante la formulación dual.




FIGURA 2.3.2-2: Ajuste de margen suave de pérdida para una SVR lineal. Fuente: (Smola & Scholkopf, 1998).

Formulación dual de la SVR

Para obtener la formulación dual del problema es necesario construir la función de Lagrange la cual implica la introducción de nuevas variables y queda de la forma que se puede observar en la ecuación 2.10.

$$\begin{aligned}
 L(\vec{w}, b, \xi_i, \xi_i^*, \lambda_i, \lambda_i^*, \beta_i, \beta_i^*) = & \frac{1}{2} \|\vec{w}\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) \\
 & - \sum_{i=1}^n (\beta_i \xi_i + \beta_i^* \xi_i^*) \\
 & - \sum_{i=1}^n \lambda_i (\varepsilon + \xi_i - y_i + (\vec{w} \cdot \vec{x}_i) + b) \\
 & - \sum_{i=1}^n \lambda_i^* (\varepsilon + \xi_i^* + y_i - (\vec{w} \cdot \vec{x}_i) - b)
 \end{aligned} \tag{2.10}$$

Con \vec{w} como las variables primales y $\lambda_i, \lambda_i^*, \beta_i, \beta_i^*$ los multiplicadores de Lagrange (o variables duales). La característica de este problema dual es que presentan un único punto silla, el cual es la solución óptima.

Según el teorema Karush Kuhn-Tucker las derivadas parciales (ecuación 2.11) son iguales a 0 en el punto silla lo que quedaría como:

$$\begin{aligned}
\frac{\partial L}{\partial \vec{w}} &= \vec{w} - \sum_{i=1}^n \lambda_i \vec{x}_i + \sum_{i=1}^n \lambda_i^* \vec{x}_i = 0 \\
\frac{\partial L}{\partial b} &= \sum_{i=1}^n (\lambda_i^* - \lambda_i) = 0 \\
\frac{\partial L}{\partial \xi_i} &= C - \lambda_i - \beta_i = 0 \\
\frac{\partial L}{\partial \xi_i^*} &= C - \lambda_i^* - \beta_i^* = 0
\end{aligned} \tag{2.11}$$

Reemplazando en el problema original se obtiene el problema dual de la SVR dado en la ecuación 2.12 (Smola, Murata, Schölkopf, & Klaus-Robert, 1998b).

$$\begin{aligned}
\text{Maximizar:} \quad D(\lambda_i, \lambda_i^*) &= -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (\lambda_i - \lambda_i^*)(\lambda_j - \lambda_j^*)(\vec{x}_i * \vec{x}_j) \\
&\quad - \varepsilon \sum_{i=1}^n (\lambda_i + \lambda_i^*) + \sum_{i=1}^n y_i (\lambda_i - \lambda_i^*) \\
\text{Sujeto a:} \quad &\sum_{i=1}^n (\lambda_i - \lambda_i^*) = 0 \\
&0 \leq \lambda_i \leq C \\
&0 \leq \lambda_i^* \leq C
\end{aligned} \tag{2.12}$$

Regresión no lineal

Raramente es posible encontrar solución a este tipo de problemas utilizando tan solo regresiones del tipo lineal. A veces resulta necesario aplicar una transformación de los datos de entrada mediante el uso de una función Φ , a un espacio de soluciones de mayor dimensión que contenga la perspectiva para aplicar la regresión lineal del problema. Esta transformación se basa en la dependencia de los productos punto entre los datos de entrada, y se realiza utilizando las funciones Kernel representadas por la función $K(\vec{x}_i, \vec{y}_i) = \Phi(\vec{x}_i) \cdot \Phi(\vec{y}_i)$.

Funciones Kernel

La validación de una función Kernel está dada por la condición de Mercer (Burges, 1998), que indica que una función es Kernel sí y solo sí para cualquier $g(\vec{x}_i)$ la fórmula 2.13 da como resultado un número finito y por lo tanto se cumple que:

$$\int g(\vec{x}_i)^2 dx \tag{2.13}$$

$$\int K(\vec{x}_i, \vec{x}_j) g(\vec{x}_i) g(\vec{x}_j) d\vec{x}_i d\vec{x}_j \geq 0$$

La función Kernel cumple la definición de simetría en espacios de mayor dimensión respecto a la dimensión del espacio de entrada, y por lo tanto, que $K(\vec{x}_i, \vec{x}_j)$ sea igual a $K(\vec{x}_j, \vec{x}_i)$. Los distintos tipos de funciones Kernel se pueden apreciar en la tabla 2.2.

TABLA 2.3.2-1: Funciones Kernel de las SVM. Fuente: Miranda (2016), Varas (2013).

Nombre	Ecuación
Lineal	$K(\vec{x}_i, \vec{x}_j) = \vec{x}_i \cdot \vec{x}_j$
Polinomial (grado m)	$K(\vec{x}_i, \vec{x}_j) = (\vec{x}_i \cdot \vec{x}_j + b)^m$
RBF	$K(\vec{x}_i, \vec{x}_j) = e^{\frac{-\ \vec{x}_i - \vec{x}_j\ ^2}{2\sigma^2}}$
Sigmoidal	$K(\vec{x}_i, \vec{x}_j) = \tanh(k\vec{x}_i \cdot \vec{x}_j + \theta)$

La función Kernel lineal es utilizada en la formulación lineal de las máquinas de vectores soporte, la polinomial corresponde a la formulación no lineal, la función Kernel radial (*Radial Basis Function*, RBF) es la más utilizada en estudios de este tipo para modelamientos no lineales con muy buenos resultados, y finalmente, la función Kernel sigmoidal es similar a las utilizadas en las redes neuronales artificiales.

2.3.3. OPTIMIZACIÓN

La optimización hace referencia a la obtención del mejor resultado dado un criterio dentro del conjunto solución. Los casos más simples de optimización son los de maximizar o minimizar una función objetivo en base a parámetros de entrada restringidos (conjunto acotado).

La optimización corresponde a un área de las matemáticas que presenta grandes aplicaciones en distintas áreas de la ciencia para el campo de la AC no ha sido extensamente aplicado, es por eso que representa un campo inexplorado el cual podría entregar resultados tanto favorables como inefectivos.

Puntualmente, la rama de la optimización que podría tener efecto en el estudio de la AC es la OMO, la cual será explicada en la sección siguiente. Pero corresponde establecer el contexto de la optimización, por lo que corresponde explicar qué es la optimización desde su forma más básica, esto es la programación lineal.

Programación lineal

La programación lineal (PL) corresponde a un método de la optimización restringida encargada de alcanzar ciertos objetivos establecidos (e.g. minimizar o maximizar funciones), en base a restricciones que representan recursos limitados.

Los problemas de PL constan de 2 partes, una función objetivo y sus correspondientes restricciones. La función objetivo es lo que se desea optimizar y las restricciones son las limitaciones del problema. En un problema PL la función objetivo tiene la siguiente forma de la ecuación 2.14.

$$Z = c_1x_1 + c_2x_2 + \cdots c_nx_n \quad (2.14)$$

Con c_j correspondiente a la contribución de j -ésima actividad realizada para alcanzar el objetivo, y x_j la magnitud de la j -ésima actividad. Esta función es equivalente a la suma de las contribuciones de las n actividades (Chapra & Canale, 2006; Taha, 2012).

Cada actividad está limitada a la disponibilidad de recursos, por lo que estos deben presentarse como restricciones representadas en la ecuación 2.15.

$$a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n \leq b_i \quad (2.15)$$

Siendo a_{ij} la cantidad consumida de cada recurso i por cada actividad j , y b la cantidad disponible del recurso i . Esto define los límites de los recursos disponibles.

Finalmente siempre existe la restricción $x_i \geq 0$ que explica que todas las actividades deben tener un valor positivo, esto porque es físicamente imposible definir una actividad negativa (e.g. la producción de bienes negativos).

Estas dos partes conforman los problemas de PL y son la base de los problemas de optimización.

Visualmente también es posible entender la PL, ya que si se observa en un mapa cartesiano (donde los ejes corresponden a las dimensiones de las actividades), es posible delimitar áreas que representan el conjunto solución factible. Dependiendo de si el problema es de maximización o minimización, es la ubicación del óptimo. Una de las ventajas de la representación gráfica es que permite observar si existen soluciones únicas o alternativas, así como también descarta las soluciones no factibles (fuera del conjunto solución). La desventaja principal de este método es que limita su aplicación a problemas de dos o 3 dimensiones. En la figura 2-3 se puede ver un ejemplo de maximización. Se puede ver que existe una solución que optimiza la condición objetivo que es maximizar el valor final de la función.




FIGURA 2.3.3-1: Problema de PL para la función objetivo $z=4x+3y$. Fuente: Caramia (2008).

La optimización establece la gama de soluciones posibles y permite obtener la mejor respuesta en base a la función objetivo.

Optimización multi-objetivo

Los problemas de optimización resultan ser uno de los más frecuentes en la actualidad (Jaimes & Coello, 2008; Nagrath, Bequette, & Cramer, 2005; Chaudhari, Dharaskar, & Thakare, 2010; Amarilla, Almeida, & Barán, 2004) mostrando buenos resultados cuando se aplican las técnicas de resolución. Este tipo de problemas, en la realidad, considera otros factores (Erkut, Tjandra, & Verter, 2007) lo que ha implicado buscar optimizar la función de un solo objetivo. Para estos casos es necesario introducir una mayor cantidad de restricciones para simplemente poder controlar los nuevos factores. El objetivo macro para este tipo de problemas es poder potenciar el nivel de equidad de las variables en estudio. La evolución de esta resolución ha convergido en el marco de la OMO.

Los problemas de OMO contemplan variedad (ecuación 2.16) a nivel de función objetivo.

$$\min f(x) \rightarrow \min[f_1(x), f_2(x), \dots, f_n(x)]$$

$$x \in S \quad (2.16)$$

Donde
$$S = \{x \in R^m: h(x) = 0, g(x) \geq 0\}$$

El vector objetivo pertenece a lo que es llamado espacio objetivo y el conjunto de soluciones factibles corresponde al conjunto alcanzado y se denota como $C = \{y \in R^n: y = f(x), x \in S\}$.

El concepto de optimalidad no aplica en la OMO, para esto se utiliza la acepción definida por Wilfredo Pareto (Ngatchou, Zarei, & El-Sharkawi, 2005) la cual busca obtener el mayor beneficio considerando una serie de factores, esto será explicado en la siguiente sección.

Para la OMO se dice que un vector solución x^* es Pareto óptimo si todos los demás vectores $x \in S$ tienen un valor resultante mayor o igual para por lo menos una de las funciones f_i con $i = 1, 2, 3, \dots, n$.

Formalmente se restringe por las siguientes definiciones:

- Un punto x^* es una solución Pareto óptima débil sí y solo sí no existe una solución x tal que $f_i(x) < f_i(x^*) \forall i$.
- Un punto x^* es una solución Pareto óptima fuerte sí y solo sí no existe una solución x tal que $f_i(x) \leq f_i(x^*) \forall i$, con al menos una igualdad estricta.

Los elementos pertenecientes al conjunto de las soluciones Pareto óptima fuerte son llamados soluciones dominantes. Por el contrario, los elementos del conjunto solución débil son llamados soluciones dominadas. El conjunto de soluciones dominantes dibujadas en un plano es llamado el frente de Pareto. En la figura 2-4 se puede apreciar como existen elementos que bajo el concepto de Pareto poseen dominancia sobre el resto de los elementos.




FIGURA 2.3.3-2: El punto A contempla a una solución factible la cual es dominante respecto a los puntos B - F ya que posee un valor mínimo para f_1 ante ambos casos y un valor igual o menor para f_2 . Los puntos C - D dominan a A – B – F por las mismas características.

En la figura 2-5 se puede observar cómo se conforman las soluciones en la OMO. Se subentiende que para dos o más dimensiones se puede encontrar una serie de soluciones posibles y factibles que optimizan de mejor forma que el resto del conjunto solución.




FIGURA 2.3.3-3: Conjunto de soluciones factibles C , donde la línea sobresaltada corresponde al conjunto dominante. Los elementos del conjunto dominante satisfacen el objetivo general que es minimizar ambas funciones $f_1(x)$ y $f_2(x)$. Fuente: Caramia (2008).

Este tipo de solución implica encontrar un buen intercambio entre los criterios en estudio u objetivos. En síntesis, el objetivo es definir un conjunto solución Pareto óptimo tal que se obtenga un incremento en al menos uno de los criterios de decisión sin decrementar uno o más de los restantes (Coello, 2003).

CAPÍTULO 3. MATERIALES Y MÉTODOS

3.1. SUJETOS Y MEDICIONES

El inicio del preprocesamiento corresponde a la selección de las señales utilizadas para el estudio. Es importante hacer notar que el presente estudio corresponde a un trabajo basado en el trabajo de título realizado por Miranda (2016), por lo que es sumamente importante replicar el experimento utilizando las mismas señales y consecuentemente los mismos individuos.

Las señales corresponden a variaciones espontáneas de presión las cuales son preprocesadas para su posterior análisis autorregulatorio utilizando técnicas informáticas de minería de datos.

Cabe hacer notar que los sujetos tienen un promedio de edad de $31,8 \pm 8,5$ años entre un rango de 23 a 51. Ninguno de los sujetos posee historial de enfermedad cardiovascular, hipertensión, migraña, epilepsia, aneurisma cerebral, sangrado intracerebral o algún tipo de desorden neurológico preexistente. El estudio fue aprobado por el *Leicestershire Research Ethics Committee*, y los consentimientos informados fueron obtenidos previamente.

Las grabaciones de las muestras fueron obtenidas en posición supina con la cabeza elevada en un ángulo de 30° . La VFSC fue medida en la arteria cerebral media con un sistema Doppler Transcraneal Scimed QVL-120 en conjunto con un transductor de 2 MHz colocado con una banda elástica en la cabeza. La localización de la arteria cerebral media se realizó mediante la ventana transtemporal para la arteria derecha.

Un finómetro permite obtener la presión sanguínea arterial continua de forma no invasiva, con la cual mediante una interpolación latido a latido permite obtener la PAM. El modelo de finómetro utilizado es Ohmeda 2300 Finapres BP.

PAM y VFSC fueron grabados antes, durante y después de la inducción de la caída de presión, la cual fue realizada mediante la técnica de la liberación de los manguitos de presión sanguínea (Tiecks, Lam, Aaslid, & Newell, 1995), que consta de poner un manguito de presión en cada pierna a la altura del muslo, inflando ambos para aumentar la presión sanguínea en el cuerpo y luego liberarlos. La oclusión de presión sanguínea se mantuvo por 2 minutos y luego fue liberada para inducir una caída de presión sanguínea transiente.

El procedimiento se realizó 6 veces en cada sujeto con un intervalo de 8 minutos o más entre cada maniobra con el fin de estabilizar la PAM y VFSC a sus valores base. Para efectos de este estudio solo se consideraron 2 muestras representativas de cada individuo, ya que el estudio inicial (Mahony, Panerai, Deverson, Hayes, & Evans, 2000) concluye que se puede obtener resultados de índices autorregulatorios con 2 muestras, haciendo que más experimentaciones sea estadísticamente redundantes.

Las muestras fueron acortadas a 2 minutos y cada una dividida en 2 secciones, para poder realizar la validación cruzada, ya que el estudio realizado por Gajardo (2014) demuestra que basta con tan solo 1 minuto de muestra para poder encontrar resultados válidos.

Para incluir los efectos del CO_2 , una cantidad del 5% en el aire fue suministrado a cada sujeto. Se utilizó un capnógrafo infrarrojo con una máscara facial para medir la exhalación de CO_2 ($EtCO_2$). Finalmente se obtiene una señal mediante una interpolación polinomial con una frecuencia de 5 Hz con un tiempo de muestreo de 0.2 segundos.

3.2. PREPROCESAMIENTO DE DATOS

Cada señal tenía una frecuencia de 5 Hz con un tiempo de muestreo de 0.2 segundos los cuales después fueron submuestreados a 0.5 segundos para concordar con el estudio realizado por Miranda. Posteriormente las señales fueron seccionadas en 2 muestras de un minuto cada una con el fin de poder realizar los correspondientes entrenamientos y pruebas basadas en el análisis de validación cruzada.

Los registros de datos fueron obtenidos en base al estudio original de Mahony (2000), el cual presenta las señales de los 16 individuos. Para estas señales se realizó el siguiente procedimiento:

- Cada señal posee aproximadamente 8 minutos de grabaciones obtenidas durante los intervalos de recuperación de presión realizados entre cada ejercicio de manguito realizado en el estudio original (Mahony, Panerai, Deverson, Hayes, & Evans, 2000).
- Se realizó un corte en cada señal de 120 segundos para así obtener 2 minutos los cuales son suficientes para no poseer variaciones en los resultados de los experimentos (Gajardo, 2014). De esta forma se obtuvieron 2 muestras por sujeto lo que equivale a 32 registros finales.
- Posteriormente se realiza la normalización de los datos, dada por la ecuación 3.1.

$$x_n(t) = \frac{x(t) - x_{min}}{x_{max} - x_{min}} \quad (3.1)$$

Donde $x(t)$ corresponde a la muestra en el tiempo t , y las otras variables son las muestras de valor mínimo y máximo.

- Con las señales normalizadas se procedió a realizar los entrenamientos respectivos dadas las estrategias de modelamiento.

3.3. ESTRATEGIA DE MODELAMIENTO

3.3.1. Estructura de los modelos

Para el presente estudio se utilizaron 4 modelos de entrenamiento multivariado:

- *Finite Impulse Response* (FIR).
- *Non Linear Finite Impulse Response* (NFIR).
- *Auto-regression With Exogenous Variables* (ARX).
- *Non Linear Auto-regression With Exogenous Variables* (NARX).

Todos los modelos fueron entrenados utilizando máquinas de vectores soporte. Las entradas utilizadas en los modelos son la PAM y etCO_2 , y la salida del modelo corresponde a la VFSC. Para los modelos autoregresivos se utiliza también la VFSC como variable de entrada.

La estructura de los modelos se puede ver en las figuras 3-1, 3-2, 3-3 y 3-4. Cabe hacer notar que para las estructuras regresivas, las velocidades de flujo ingresan al sistema como retardos en el tiempo, los cuales no se especifican en la imagen.

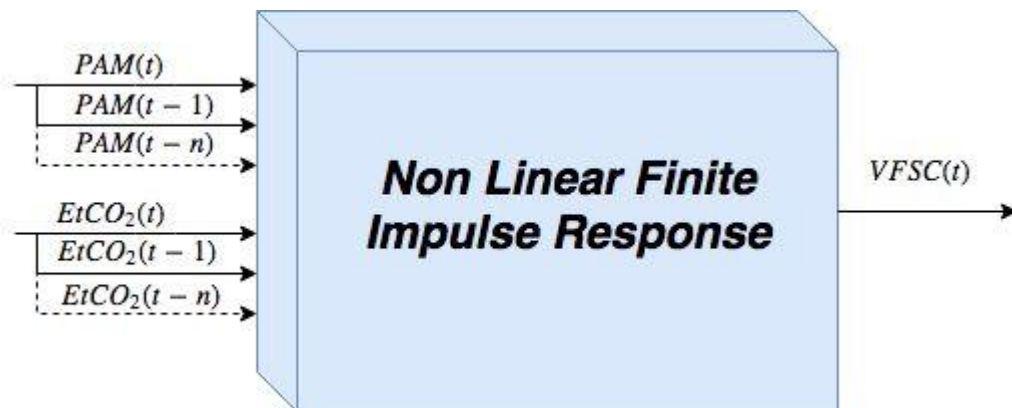


FIGURA 3.3.1-1: Estructura general del modelo FIR. Fuente: Elaboración propia, 2017.

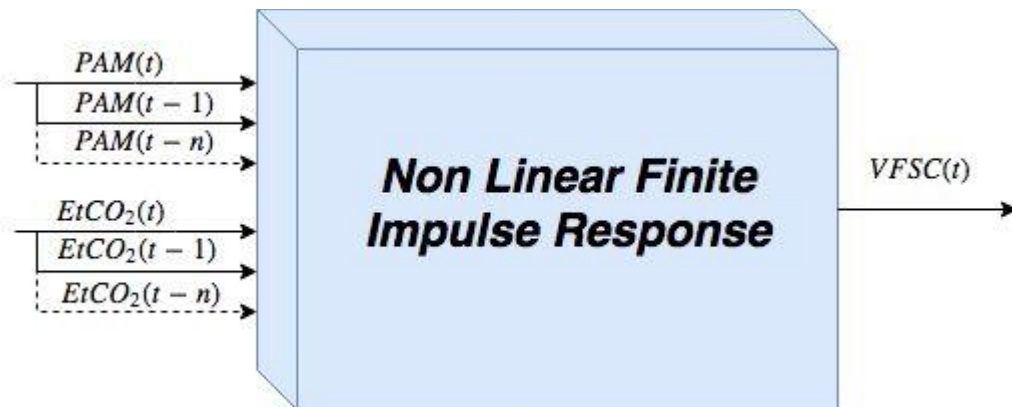


FIGURA 3.3.1-2: Estructura general del modelo NFIR. Fuente: Elaboración propia, 2017.

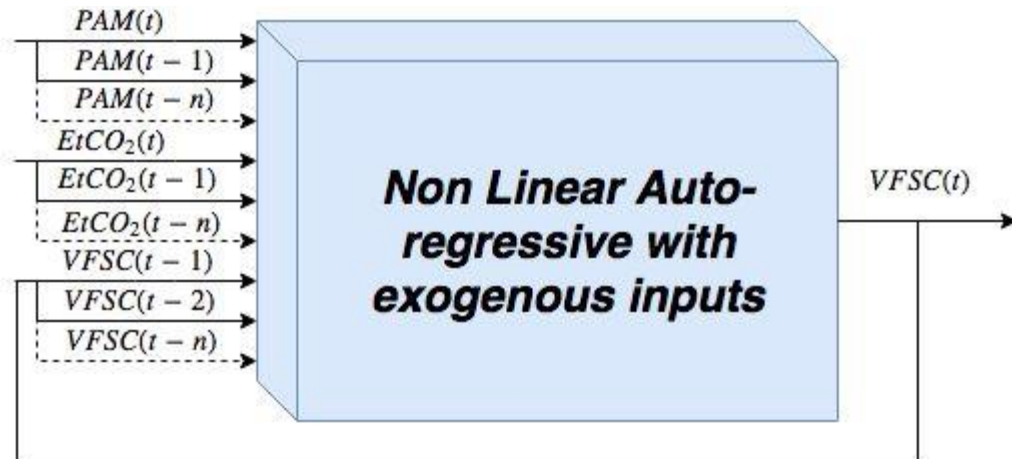


FIGURA 3.3.1-3: Estructura general del modelo ARX. Fuente: Elaboración propia, 2017.

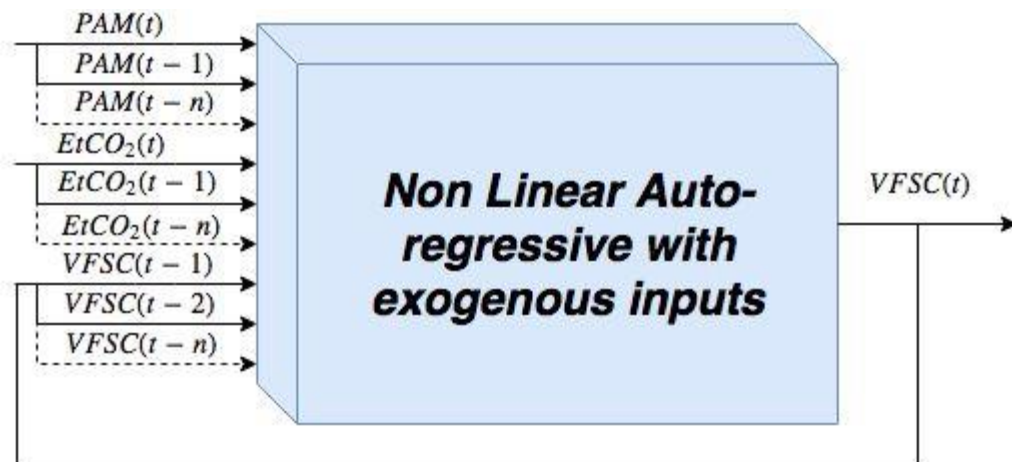


FIGURA 3.3.1-4: Estructura general del modelo NARX. Fuente: Elaboración propia, 2017.

3.3.2. Validación de los modelos

Para la validación de los entrenamientos se utiliza la técnica de validación cruzada. El presente estudio utiliza las VE de 2 minutos seccionadas a un minuto cada una, con el fin de realizar la validación previamente mencionada y, por otro lado, mantener concordancia entre las dos señales evaluadas siendo una la continuación de la otra.

La primera sección de la señal se utiliza como entrenamiento y se valida con la segunda sección. Posteriormente se realiza la operación a la inversa, *i.e.* se entrena con la segunda sección de la señal y se valida con la primera.

3.3.3. Selección de los parámetros

Dadas las características de las SVM es posible obtener variados resultados en base a los hiperparámetros escogidos para los entrenamientos. Los modelos lineales ocupan los hiperparámetros nu y $costo$ (C). Los modelos no lineales utilizan un Kernel radial por lo que agregan el hiperparámetro $sigma$ (σ).

Uno de los objetivos principales de este estudio es poder hacer un análisis comparativo de los resultados propios *versus* los de un estudio previo, por lo que idealmente se esperaba obtener una gama amplia de posibilidades de modelos. Para lograr esto se ampliaron vastamente los límites de las secuencias de hiperparámetros.

Se utilizaron dos enfoques de selección del hiperparámetro C , con el fin de analizar si existían variaciones en el comportamiento de los modelos dado un crecimiento exponencial o lineal del parámetro. El enfoque lineal implica 15 valores equidistantes entre $2^{-2} = 0,25$ y $2^{12} = 4.096$, mientras que el enfoque exponencial implica un costo variable entre los mismos valores pero definido por las potencias de 2, *i.e.* $2^{-2}, 2^{-1}, 2^0, \dots, 2^{12}$.

Para poder realizar este contraste a cada individuo del estudio se le promediaron los índices ARI y mfARI de forma separada, con el fin obtener una población representativa para cada individuo y modelo. Se les realizó un test Shapiro-Wilk para analizar la normalidad de los conjuntos.

La tabla 3.1 resume los hiperparámetros utilizados en el trabajo, se observa la variable costo en ambos enfoques propuesto. En el caso del costo lineal se tomaron un valor inicial y final, $[2^{-2}, 2^{12}]$ y se obtuvieron 15 valores equidistantes considerando estos límites.

TABLA 3.3.3-1: Retardos utilizados en las estructuras de los modelos e hiperparámetros utilizados para el estudio de los modelos de entrenamiento. Fuente: Elaboración propia, 2017.

Parámetro	Valor de parámetro en FIR / NFIR	Valor de parámetro en ARX / NARX
Retardos PAM	1,2,3,...,8	1,2,3,...,8
Retardos EtCO ₂	1,2,3,...,6	1,2,3,...,6
Retardos VFSC	1,2,3,...,6	1,2,3,...,6
Hiperparámetro C (Exponencial)	0.25, 0.5, 1, 2, 4, 8, 16, 32, 64, 128, 256, 512, 1024, 2048, 4096	0.25, 0.5, 1, 2, 4, 8, 16, 32, 64, 128, 256, 512, 1024, 2048, 4096
Hiperparámetro C (Lineal)	0.25, 292.8, 585.36, 877.91, 1170.46, 1463.02, 1755.57, 2048.13, 2340.68, 2633.23, 2925.79, 3218.34, 3510.89, 3803.45, 4096	0.25, 292.8, 585.36, 877.91, 1170.46, 1463.02, 1755.57, 2048.13, 2340.68, 2633.23, 2925.79, 3218.34, 3510.89, 3803.45, 4096
Hiperparámetro nu	0.1, 0.2, 0.3, ..., 0.9	0.1, 0.2, 0.3, ..., 0.9
Hiperparámetro σ	$2^{-4}, 2^{-2}, 2^0, \dots, 2^{10}$	$2^{-4}, 2^{-2}, 2^0, \dots, 2^{10}$

3.3.4. Algoritmo de Optimización multi-objetivo

Para la utilización del método de optimización multi-objetivo existen disponibles variados métodos que se fundamentan principalmente en la obtención de lo óptimos utilizando algoritmos evolutivos (Deb, 2001; Zitzler, Laumans, & Thiele, 2001).

Como particularmente ese no es el enfoque de estudio, fue necesaria la creación de un algoritmo que permita evaluar encontrar los óptimos en 5 variables, dadas las funciones objetivos. Para esto se ha realizado un algoritmo que, utilizando el enfoque de fuerza bruta, permite obtener los mejores modelos dados 5 factores de interés abordando así la optimización de cada uno de ellos.

Los factores a optimizar y su objetivo se pueden ver en la tabla 3.2 y su descripción se puede ver en la sección 3.5.

TABLA 3.3.4-1: Objetivos de la optimización multi-objetivo. Fuente: Elaboración propia, 2017.

Factor	Objetivo
<i>Vectores de Soporte</i>	<i>Minimizar</i>
<i>Nu</i>	<i>Minimizar</i>
<i>Cost</i>	<i>Minimizar</i>
<i>Retardos</i>	<i>Minimizar</i>
<i>Correlación</i>	<i>Maximizar</i>

A modo de explicación el algoritmo se presenta en pseudocódigo.

```

M <- MODELOS
M(suma) <- M(retardoPAM)+M(retardoC02)
PARA
  (CADA vector de soporte diferente(M) ->VS)
    SetVS <- Elementos(M) donde M(VS) == VS
    PARA (CADA nu diferente(SetVS) ->nu)
      SetNu <- Elementos(SetVS) donde SetVS(nu) == nu
      PARA(CADA cost diferente(SetNu) ->cost)
        SetCost <- Elementos(SetNu) donde SetNu(cost) == cost
        PARA(CADA suma diferente(SetCost) ->suma)
          SetSuma <- Elementos(SetCost) donde SetCost(suma) == suma
          máximoCorrelación <- máximo(SetSuma(correlación))
          elemento <- SetSuma(correlación) == máximoCorrelación
          SI(Pareto == VACIO)
            agregar elemento
          SINO
            PARA(CADA elemento_Pareto)
              comparar(elemento,elemento_Pareto)

```

FIGURA 3.3.4-1: Pseudocódigo de la implementación del frente de Pareto. Fuente: Elaboración propia, 2017.

El pseudocódigo muestra cómo se navegan todas las combinaciones posibles, tal como se puede ver en la figura 3-5, siguiendo un orden creciente es posible obtener los diferentes frentes de Pareto y superponerlos evaluando la optimización en cada factor. Dados los 5 factores, éstos se presentan en un orden tal que se estandarizan todos los modelos al formato *Retardos vs Correlación* (figura 3-6). De esta forma es fácil hacer una comparación y obtener así el frente de Pareto de toda la muestra.

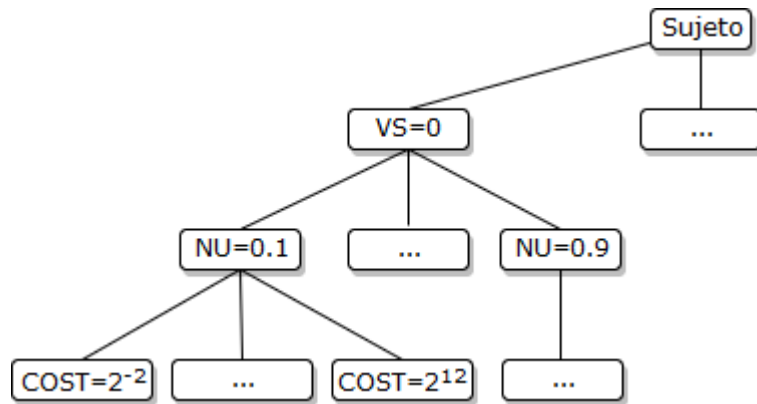


FIGURA 3.3.4-2: Árbol de navegación para obtener los distintos frentes de Pareto. Los nodos con puntos suspensivos corresponden a los posibles valores obtenidos por cada factor y sus combinaciones. Cada nodo hoja finaliza obteniendo un frente de Pareto individual Retardos versus Correlación. Fuente: Elaboración propia, 2017.




FIGURA 3.3.4-3: Frente de Pareto (puntos azules) dominando a los modelos (puntos rojos) de menor correlación y mayor cantidad de retardos. Fuente: Elaboración propia, 2017.

Con los modelos optimizados y estandarizados a 2 variables es más fácil realizar la comparación enfocándose en la optimización de los 5 objetivos. Los modelos son procesados en el *software* R y de esta forma se obtiene una frontera de Pareto que corresponde a los mejores modelos. Así se tiene un subconjunto de datos desde donde se puede escoger el modelo representativo para el estudio.

A modo de ejemplo se puede observar la figura 3-7, donde se encuentra un frente de Pareto (de color azul) y un conjunto de modelos dominados (de color rojo) para un análisis de 3 dimensiones (Costo – Correlación – Retardos). Se observa cómo los puntos azules contienen a los puntos rojos en el sentido de la optimización de los factores, que para este caso sería disminuir el costo y los retardos y, por el contrario, aumentar la correlación.

3.4. Reglas de asociación

Una de las técnicas más conocidas en la minería de datos es la identificación de reglas de asociación que permiten subentender comportamientos en un conjunto de datos. Estos comportamientos se basan en instancias de transacciones donde se contabiliza la cantidad de ocurrencias para una condición dada (lado izquierdo de la regla) y un consecuente resultado (lado derecho de la regla).

Para efectos de este estudio se utiliza el algoritmo *Apriori*, el cual consiste en definir 2 parámetros, que permiten analizar si existen patrones predominantes:

- Soporte: Razón de la cantidad de ocurrencias de una transacción en el conjunto de datos. Considera solamente las ocurrencias en la condición.
- Confianza: Razón de la cantidad de transacciones con un resultado fijo sobre el soporte de la condición.

Existe un tercer parámetro llamado la “mejora del soporte” (o en inglés *lift*) que depende de los dos parámetros anteriores y muestra el impacto en términos de beneficio para el conjunto de datos.

La definición de los valores soporte y confianza dependen en estricto rigor del tipo de estudio. Considerando que se está intentando obtener patrones sobre un número extenso de combinaciones valores relativamente pequeños bastarían para obtener patrones válidos.

El uso del algoritmo *Apriori* permite volver a hacer un análisis sobre el frente de Pareto para encontrar comportamientos que permitan acotar aún más los resultados en función de una mejor calidad.

Para utilizar las reglas de asociación es necesario considerar la discretización de variables. Las variables consideradas son los factores de la optimización: nu, costo, número de vectores de soporte, calidad de la señal, correlación.

En la tabla 3.3 se puede observar el criterio utilizado para discretizar cada variable y sus valores respectivos. Esta discretización se realiza en base a una inspección visual de los modelos repartidos en el plano cartesiano. En la tabla 3.4 se observa la categorización para el índice de calidad.

TABLA 3.4-1: Discretización de las variables utilizadas en la optimización. Fuente: Elaboración propia, 2017.

Variable	Rangos
Cantidad de Retardos	[1, 5]
	(5, 10]
	(10, 15]
	(15, 20]
Correlación	[0.0, 0.25]
	(0.25, 0.5]
	(0.5, 0.75]
	(0.75, 1.0]
Cantidad de Vectores de Soporte	[0, 50]
	(50, 100]
	(100, 150]
	(150, 200]
Costo	[0, 32]
	(32, 256]
	(256, 1024]
	(1024, 4096]
nu	0.1
	0.2
	0.3
	0.4
	0.5
	0.6
	0.7
	0.8
	0.9

TABLA 3.4-2: Categorización de la Calidad. Fuente: Elaboración propia, 2017.

Valor de la Calidad	Criterio
[1.0, 5.0]	Baja
(5.0, 7.5]	Normal
(7.5, 9.0]	Alta
(9.0, 10.0]	Muy Alta

3.5. CRITERIOS DE EVALUACIÓN

Estadísticos

3.5.1. Coeficiente de correlación

El coeficiente de correlación (CC) es un indicador que informa la dependencia entre variables, para el contexto de las señales explica el nivel de similitud entre las señales en estudio, principalmente se evalúa la similitud entre la señal predicha (en base a la señal de entrenamiento) y sección contigua de validación.

El CC está definido por la ecuación 3.2.

$$CC = \frac{\sum_{i=1}^N (v(i) - \bar{v}) \times (\hat{v}(i) - \bar{\hat{v}})}{\sqrt{\sum_{i=1}^N (v(i) - \bar{v})^2} \times \sqrt{\sum_{i=1}^N (\hat{v}(i) - \bar{\hat{v}})^2}} \quad (3.2)$$

El valor del CC varía entre -1 y 1, donde -1 corresponde a que ambas señales son completamente opuestas, 0 equivale a que las señales no tienen relación y 1 implica que poseen el mismo comportamiento. En este punto cabe hacer notar que correlaciones muy altas pueden implicar que el modelo sobre-aprendió del entrenamiento.

Para el presente estudio no se considera el error ya que en el estudio realizado por Miranda (2016) no contempla el error para calcular el puntaje.

3.5.2. Test de Shapiro-Wilk

El test de Shapiro-Wilk es un test que contrasta la normalidad de un conjunto de datos. La normalidad de los datos es una de las asunciones más comunes cuando se utilizan procedimientos estadísticos (Hanusz, 2014).

Este test está restringido para una cantidad de muestras menor a 50 (Razalt, 2011). El estadístico, a partir de la base de un conjunto ordenado de datos como muestra, se define como la ecuación 3.3 (Shapiro, 1965):

$$W = \frac{(\sum_{i=1}^n a_i y_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (3.3)$$

Con y_i como el i -ésimo valor de la muestra y \bar{y} como el promedio de la muestra (ecuación 3.4), el escalar a_i se define como:

$$a_i = (a_1, \dots, a_n) = \frac{m^T V^{-1}}{(m^T V^{-1} V^{-1} m)^{\frac{1}{2}}} \quad (3.4)$$

Con m como el vector $(m_1, \dots, m_n)^T$ de valores esperados de los elementos ordenados pertenecientes a las variables aleatorias distribuidas muestreadas desde la distribución normal estándar y V como la covarianza de la muestra.

El valor del resultado se mueve entre 0 y 1. Si el valor es pequeño (<0.05) se rechaza la hipótesis nula la cual indica que el conjunto proviene de una distribución normal.

Para efectos de estudio se utilizará para comprobar la normalidad de los conjuntos y de esta forma seleccionar qué prueba realizar para evaluar diferencias.

3.5.3. T-test

El estadístico t de Student es un método para evaluar si un conjunto de datos fue obtenido a partir de un conjunto de datos original o, desde otra perspectiva, si dos conjuntos de datos son significativamente diferentes. Para esto se utiliza los promedios y las desviaciones estándar de cada conjunto, y se evalúa si es que estos se alejan mucho uno del otro. Si los valores calculados se desvían mucho de los originales entonces se dice que los conjuntos no son significativamente iguales.

El estadístico se ve en la ecuación 3.5:

$$t = \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}} \quad (3.5)$$

Para una desviación estándar s , promedio de la muestra a evaluar \bar{x} , n el total de muestras y μ promedio de la muestra original.

El resultado permite observar qué tan grandes son las diferencias entre ambos conjuntos. Para un valor muy grande se sigue la idea de que los conjuntos son diferentes, por el contrario, un valor pequeño implica que los conjuntos son similares. De esta forma esta prueba permitirá establecer si es que las muestras a evaluar (conjunto frente de Pareto y conjunto de modelos dominados) son significativamente diferentes.

3.5.4. Respuesta al escalón de presión

Para evaluar si efectivamente se obtuvieron resultados que reflejen el fenómeno de la autorregulación es necesario realizar un análisis sobre los modelos entrenados. Este análisis parte de una base simple la cual es que al realizar variaciones en la PAM se observan reacciones por parte de la VFSC. Esto quedó demostrado en los estudios realizados previamente (Aaslid, Lindegaard, Sorteberg, & Nornes, 1989; Tiecks, Lam, Aaslid, & Newell, 1995) donde se observó que presenta una estabilización más rápida que la PAM con una autorregulación alta, mientras que en el caso contrario, con una baja autorregulación la VFSC tiende a seguir el comportamiento de la PAM. Sea cual sea el comportamiento de la VFSC se ha observado que en sí, la AR se estabiliza en un periodo variable entre 20 y 30 segundos (Greenfield, Rembert, & Tindall, 1984).

De esta forma es necesario emular esta variación en la PAM. Esto se realiza con la inserción de un escalón de presión invertido que simula esta caída brusca de presión en el cuerpo humano, ya que como fue mencionado en capítulos anteriores no es viable experimentar variaciones bruscas de presión en individuos con algún tipo de afección a nivel cerebral, ya que cualquier cambio de magnitud en su presión sanguínea podría afectar negativamente al individuo.

Al escalón de presión se le aplicó un filtro *Butterworth* de orden 2 con una frecuencia de corte igual a 0,2 Hz, el cual fue muestreado a 0.5 segundos.

Con la respuesta obtenida es posible validar visualmente la señal para establecer si calza dentro de los rangos establecidos en los índices autorregulatorios existentes. Este filtro visual ha sido utilizado en muchos trabajos previos (Ramos, y otros, 2006; Varas, 2013; Ruz, 2009) y permite descartar las señales que no cumplan con ciertas características básicas, las cuales se basan en los rangos entre los que se mueven las curvas autorregulatorias definidas por *Aaslid – Tiecks* (la cual puede observarse en la siguiente sección y sus valores en el apéndice).

Los 4 criterios visuales que conforman el filtro inicial son:

- *Peak* de la caída entre 3 y 9 segundos desde que se inicia la respuesta autorregulatoria. El valor mínimo alcanzado por este punto debe estar entre el rango $[-0,2; 0,5]$.
- Tendencia de estabilización de la señal entre los 15 y 30 segundos, considerando que la señal no posea una varianza mayor a 0,002, buscando así minimizar el error.
- Valor mínimo de la respuesta autorregulatoria debe ser mayor a -0,2.
- Valor máximo de la respuesta autorregulatoria debe ser menor a 1,2.

La figura 3-8 refleja los 4 criterios recién descritos en una respuesta autorregulatoria.

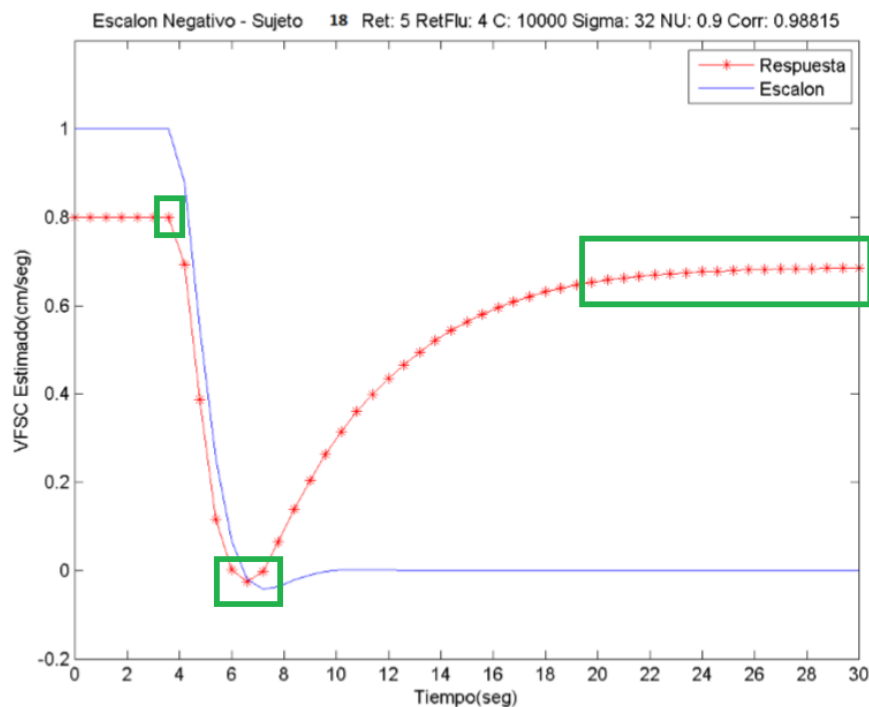


FIGURA 3.5.4-1: Características de filtro visual básico para la selección de señal. De izquierda a derecha – en el primer recuadro se observa el valor máximo inferior a 1.2, en el segundo recuadro se observa el valor mínimo de la respuesta superior a -0.2 y que se encuentra entre los segundos 3 y 9, finalmente en el recuadro de la derecha se observa una tendencia de estabilización constante que no presenta mayor variabilidad entre sus puntos. Fuente: Noh (2014).

3.5.5. Filtro avanzado

Posterior al filtro básico surge un nuevo filtro el cual es la base de este trabajo y sobre el cual se realiza el análisis de efectividad dado el modelo escogido por el mismo. Las características que conforman a este filtro son avanzadas y netamente en función de la señal, *i.e.* no son de carácter visual como el filtro anterior.

El funcionamiento es en base a un puntaje inicial de valor 10 que se les da a todos los modelos que pasen el filtro básico, el cual posteriormente es penalizado si es que la señal posee las siguientes anomalías (Miranda, 2016):

- Tendencia de la estabilización de la señal presenta un carácter ascendente o descendente. La penalización es acorde a la distancia recorrida desde el *peak* máximo hasta el último punto de la señal. El valor de penalización es ponderado por 100 dada la magnitud de las pendientes obtenidas (rango de centésimas).
- Caída de la señal previo a la estabilización mayor al 45% de la subida de recuperación de la señal, fundamentada en las 91 curvas teóricas de *Aaslid - Tiecks*. Si la caída es más de 45% es penalizada con el valor racional multiplicado por 10.
- Estabilización final de la señal no se encuentra al nivel del *peak* de la caída. Basado en las 91 curvas teóricas, se observa que no existe estabilización bajo ese punto, por lo que este comportamiento es penalizado por un cálculo en función de la distancia entre los puntos ponderado por 10.

3.5.6. Índices autorregulatorios

El paso posterior a la obtención de la respuesta al escalón invertido de presión es la caracterización de la señal en un rango de autorregulación. Para esto se utiliza el índice de autorregulación (ARI), el cual varía entre los valores 0 y 9 (donde 0 equivale a mala autorregulación y 9 muy buena autorregulación). Por otra parte existe otra forma de obtener el índice en base a un entrenamiento con modelos no lineales y uso de la técnica SVM. A continuación se presenta más en profundidad los fundamentos de ambos enfoques.

Auto regulation Index

Ese método creado por Aaslid-Tiecks (Tiecks, Lam, Aaslid, & Newell, 1995) posee la ventaja de que representa la relación dinámica entre PAM y VFSC en variaciones espontáneas de presión (Panerai, Dawson, Eames, & Potter, 2001). Esta relación es representada en 10 curvas teóricas que representan de buena forma el comportamiento autorregulatorio de los individuos. Las funciones 3.6, 3.7, 3.8 y 3.9 permiten obtener el cálculo del ARI.

$$\partial P = \frac{PAM - P}{P - PCC} \quad (3.6)$$

$$x_2 = x_2 + \frac{x_1 - 2D \times x_2}{f \times T} \quad (3.7)$$

$$x_1 = x_1 + \frac{\partial P - x_2}{f \times T} \quad (3.8)$$

$$mV = cVmca \times (1 + \partial P - K \times x_2) \quad (3.9)$$

Con:

- ∂P como las variaciones de presión P considerando la presión de perfusión cerebral PCC.
- x_1 y x_2 como variables de estado iguales a 0 en el tiempo de control.
- T como constante de tiempo.
- D como factor de amortiguamiento.
- K como la ganancia autorregulatoria dinámica.
- f como la frecuencia de muestreo.
- $cVmca$ como la velocidad de control en la arteria cerebral media.

Un estudio posterior logró aumentar la cantidad de curvas teóricas a 91 (Nuñez, 2003), utilizando tripletas de los valores T , D y K , las cuales fueron obtenidas mediante una interpolación de las 10 curvas originales.

De esta forma las 91 curvas quedan como se muestra en la figura 3-9:

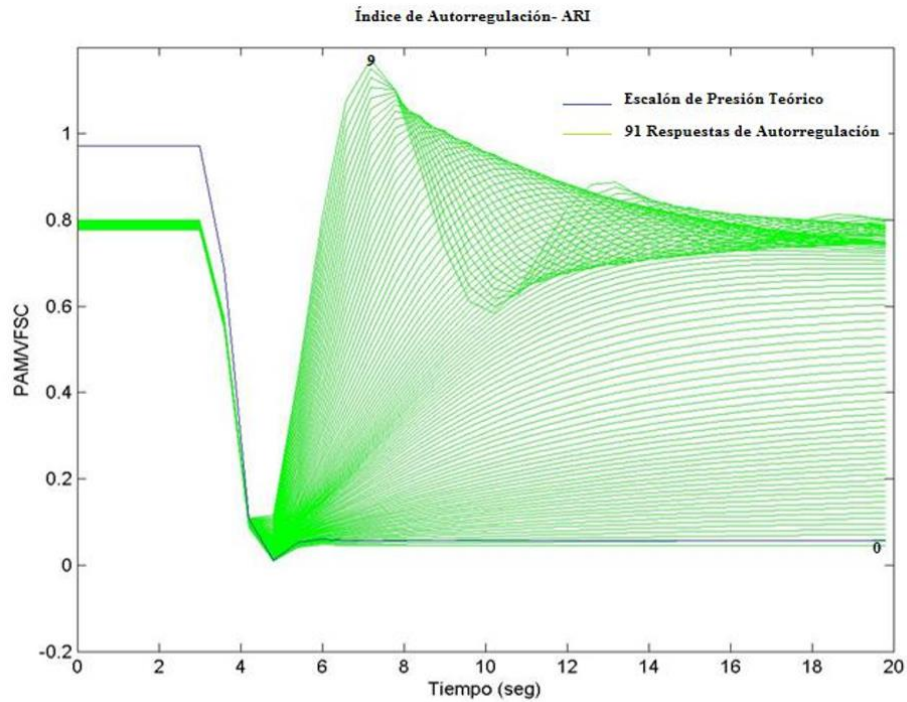


FIGURA 3.5.6-1: 91 curvas de autorregulación para variación de modelo Aaslid-Tiecks modificado. Fuente: Varas (2013).

Model Free Auto Regulation Index

El segundo método para la obtención de ARI corresponde al trabajo realizado por Chacón (2014) donde la característica fundamental recae en el uso de una regresión lineal a partir de las curvas originales de *Aaslid-Tiecks*. Este método contempla el uso de dos parámetros obtenidos directamente de la señal de respuesta al escalón: k_s que representa el estado constante de la respuesta, y $\Delta\tau$ que representa el tiempo de la respuesta transitoria. También utiliza un tercer parámetro ϕ que corresponde a la diferencia entre la pendiente de la respuesta y el escalón introducido. En la figura 3-10 se puede ver una descripción gráfica de estos parámetros.




FIGURA 3.5.6-2: Señal de respuesta a escalón introducido indicando las variables utilizadas en mfARI. Fuente: Noh (2014)

Estas 3 variables son aplicadas en la función 3.10 para el cálculo del índice mfARI.

$$mfARI = 1.587721 + 3.804129 \times k_s - 0.132812 \times \tau \times \phi \quad (3.10)$$

La finalidad de utilizar este índice es que disminuye la variabilidad intra-sujeto ya que el ARI implica tener que intentar ajustar la señal a alguna de las curvas. Esto produce una alta variabilidad en el valor del índice, por lo que mfARI ofrece mejores resultados que el índice ARI. De igual forma se obtienen ambos índices ya que son considerados en los análisis estadísticos finales.

3.5.7. Análisis de Varianza de 3 vías

El análisis de varianza (ANOVA) de 3 vías es la aplicación de un ANOVA simple sobre 3 factores y su posterior análisis de interacción entre éstos (igual que un ANOVA de dos vías pero considerando todas las posibles combinaciones). Basándose en las medias de los conjuntos permite entender si existen diferencias entre los conjuntos y, utilizando el análisis de los modelos lineales mixtos muestra cuál es el efecto de cada conjunto si es que varía el (o los) conjunto(s) restantes.

Posee el mismo comportamiento que un ANOVA de 2 vías, siendo las hipótesis las siguientes:

- Las medias de la población de la primera vía son iguales.
- Las medias de la población de la segunda vía son iguales.
- Las medias de la población de la tercera vía son iguales.
- No existe interacción entre las diferentes vías.

Como resultado entrega una tabla ANOVA de 3 vías con los efectos principales para cada variable independiente, los efectos de interacción entre variables, la dependencia entre los factores (o el error) y el estadístico que representa si existen diferencias significativas.

Su aplicación sobre el estudio permite validar en primera instancia si existen diferencias significativas entre los conjuntos Pareto y dominados (utilizando como factor base la calidad de los sujetos), lo que da a entender la validez del frente de Pareto como conjunto representativo de todo el set de datos. Si esto es válido entonces ya se esta acotando el conjunto solución sin tener que realizar una búsqueda exhaustiva de modelos, lo que implicaría ganancia en términos de optimización.

3.5.8. Variables de estudio

Las variables de estudio son los fundamentos sobre los cuales se evalúa la OMO. Dadas las características se busca minimizar o maximizar su valor. A continuación se presentan y explican los factores y sus características que determinan las funciones objetivo del presente estudio.

Correlación

La correlación contempla la semejanza entre la señal utilizada como entrenamiento y la señal de prueba. Es fundamental entender que a mayor correlación existe una mayor semejanza respecto al comportamiento de la señal de prueba *per se*. Por otro lado es importante hacer notar que es necesario fijarse bien en los resultados de la correlación, ya que una tendencia en la correlación muy alta implicaría que el modelo ha sobre-aprendido de la señal.

Esta variable permite entender la validez del modelo a utilizar respecto a la señal original (como se puede ver en la figura 3-11), de esta forma se comprende que mientras mayor la correlación (o más cercana a 1) entonces mayor precisión.




FIGURA 3.5.8-1: Señal real (azul) y señal predicha (rojo) con una correlación de 0,762. Fuente: Elaboración propia, 2017.

Complejidad

La complejidad es evaluada como la suma de retardos utilizados para el modelo específico. A mayor cantidad de retardos existe mayor complejidad en el modelo. Esta complejidad se ve reflejada directamente con los costos de procesamiento para cada modelo de aprendizaje.

Como la complejidad depende de los retardos, los modelos FIR y NFIR están en base a la PAM y el etCO_2 , mientras que los modelos regresivos ARX y NARX están en base a la PAM, etCO_2 y la CBFV, como se puede apreciar en la tabla 3-5.

TABLA 3.5.8-1: Factores de complejidad por modelo. Fuente: Elaboración propia, 2017.

Modelo	Complejidad (suma de retardos)
FIR	PAM/ EtCO_2
NFIR	PAM/ EtCO_2
ARX	PAM/ EtCO_2 /CBFV
NARX	PAM/ EtCO_2 /CBFV

Costo

El costo corresponde al valor C de los modelos, siendo uno de los llamados hiperparámetros de la SVM. El costo representa a la penalización que se le da a cada vector de soporte que es clasificado en el lado contrario del *soft margin* (Cortes & Vapnik, 1995), es decir, controla la influencia individual de los vectores soporte respecto al clasificador de la SVM.

Técnicamente hablando cada vez que se permite un elemento mal clasificado, la SVM penaliza con la función de pérdida (sección 2.4.2), siendo C el factor de penalización de la ecuación 3.11.

$$\arg \min \left\{ \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \right\} \quad (3.11)$$

La aplicación del hiperparámetro C permite producir un modelo más generalizado respecto a la separación de los conjuntos, dando un nivel holgura a la rigidez de la clasificación. Al aumentar el valor escalar del costo se aumenta también la sensibilidad al ruido en las muestras, es por esta razón que es de suma importancia realizar un análisis completo de validación cruzada y escoger la mejor opción de costo.

Nu

Por otra parte la variable Nu tiene relación directa con la cantidad de elementos presentes en el umbral de la SVM. Corresponde a la razón máxima de elementos mal clasificados posible y a la razón mínima de vectores de soporte que deben existir. Es decir, indica el porcentaje de vectores de soporte mínimo permitido y la cantidad máxima de elementos en la zona contraria del umbral. En la figura 3-12 se pueden observar los vectores soporte sobre el margen.




FIGURA 3.5.8-2: SVM con un modelo mal clasificado (triángulo), esta holgura es permitida por el factor Nu . Fuente: Hsu et al. (2003).

Vectores soporte

Los vectores soporte son otro factor de las SVM. Son aquellos modelos que delimitan el margen del hiperplano para las SVM. Esto se traduce en que mientras más vectores de soporte se tenga más difícil es clasificar los modelos, aumentando así la complejidad del modelo. La figura 3-13 muestra los vectores de soporte y su posicionamiento sobre el margen de las máquinas de vectores soporte, se observa que estos vectores definen el límite del soporte.




FIGURA 3.5.8-3: Separación dada por los vectores de soporte ubicados en la línea punteada que corresponde al margen del hiperplano. Fuente: Bülent (2003).

Dado esto el objetivo es disminuir la cantidad de vectores de soporte, lo que implicaría que la SVM separe de mejor forma los modelos.

3.5.9. CALIDAD DEL MODELO

La calidad fue expresada como una evaluación de la diferencia entre los índices ARI/mfARI para los modelos obtenidos por este estudio y los valores ARI/mfARI originales reportados en Chacón *et al.* (2014), visibles en la tabla 3-6. Cabe hacer notar que se consideraron todos los modelos válidos y fueron comparados cada uno individualmente.

Los valores originales promediados del estudio de Mahony (2000) son:

TABLA 3.5.9-1: Valores reales originales ARI y mfARI para los individuos del estudio. Fuente: Chacón *et al.* (2014).

#	Sujeto	ARI Promediado	Model free ARI Promediado
1	AN	5.3	4.2
2	AM	0.6	4.7
3	DY	4.6	5.6
4	EC	3.2	5.2
5	GB	5.8	5.8
6	H2	5.4	4.7
7	JG	4.6	6.1
8	JN	5.1	5.5
9	MS	4.2	5.9
10	PB	4.9	5.6
#	Sujeto	ARI Promediado	Model free ARI Promediado
11	PH	6.5	6.7
12	RP	5.8	6.4

13	SB	4.7	4.9
14	SH	7.1	6.9
15	TJ	4.0	4.1
16	VH	3.5	6.9

La fórmula utilizada para la evaluación se puede ver en la ecuación 3.12.

$$calidad = 10 - |(mfARI\ modelo) - (mfARI\ Mahony)| \quad (3.12)$$

El valor absoluto es restado de 10 para obtener un valor final positivo significativo que se moviera entre los rangos de los resultados originales, vale decir entre 0 y 9 que son los valores ARI sobre los que se realizó el estudio de Mahony (2000), con una unidad como holgura.

El objetivo de la creación de este criterio de calidad es poder discernir cuánto se aleja cada uno de los modelos válidos respecto de la realidad del estudio original, ya validado por Mahony.

CAPÍTULO 4. RESULTADOS

4.1. ANÁLISIS COSTO LINEAL – EXPONENCIAL

La comparación de los costos conllevó la realización de una prueba estadística que permitiera analizar si los modelos son significativamente diferentes.

Para esto se debió realizar una prueba Shapiro-Wilk para analizar la normalidad de los conjuntos y definir cuál sería el estadístico que se debía utilizar. Los resultados se ven en la tabla 4-1.

TABLA 4.1-1: Resultados de test Shapiro – Wilk para los 2 tipos de costos analizados.

	ARI		mfARI	
	Estadístico	Valor-p	Estadístico	Valor-p
Costo Exponencial	0.967	0.437	0.943	0.098
Costo Lineal	0.963	0.345	0.956	0.224

De estos resultados se puede apreciar que ambos conjuntos de muestras (tanto para los ARI como para los mfARI) son muestras que provienen de una distribución normal, lo que implica la utilización de un t-test para entender si los conjuntos son significativamente diferentes.

Los resultados se pueden apreciar en la tabla 4-2:

TABLA 4.1-2: Resultados de t – test mostrando que los conjuntos son significativamente iguales.

	Tipo de test	Estadístico	Valor p
Costos ARI	t-test	-0.360	0.720
Costos mfARI	t-test	0.115	0.909

Al ser los resultados de la prueba $>.05$ se acepta que son significativamente conjuntos iguales, por lo que estadísticamente se entiende que no existen diferencias entre realizar el entrenamiento de los modelos con un costo del tipo lineal o exponencial.

Dados estos resultados todos los análisis posteriores son llevados a cabo considerando solo el conjunto exponencial.

4.2. EVALUACIÓN DE OPTIMIZACIÓN MULTI-OBJETIVO

Para la obtención del frente de Pareto, se utilizó la implementación del algoritmo explicado en la sección 3.3.4. Como se explicó en el capítulo de la optimización multi-objetivo, la

finalidad es obtener una serie de modelos que sean los mejores respecto al resto de modelos dadas sus características.

En primera instancia el objetivo fue considerar el puntaje obtenido por el filtro avanzado utilizado en el estudio a comparar, donde **la mayoría de los resultados obtuvieron** un comportamiento similar al que se puede observar en la figura 4-1.




FIGURA 4.2-1: Análisis gráfico del puntaje obtenido por el filtro avanzado versus la Correlación. Como se puede observar existe un sesgo de los puntajes al valor 10. Fuente: Elaboración propia, 2017.

Se puede observar que no existen grandes variaciones respecto a los puntajes obtenidos por el filtro (existe un alto nivel de sesgo en la población), por lo tanto no son significativos para el estudio porque lo que se debió proceder a escoger otras variables.

Las características evaluadas como base fueron la correlación, nu, costo, número de vectores de soporte y los retardos obtenidos como la suma de retardos de MABP y CO2 (para modelos FIR y NFIR) y MABP, CO2 y VFSC (para modelos ARX y NARX).

De esta forma se obtuvieron gráficas como la que se puede observar a continuación en la figura 4-2.




FIGURA 4.2-2: Frente de Pareto de la gráfica “Retardos v/s Correlación” para un modelo FIR. Los puntos azules corresponden a los modelos que mejor satisfacen los objetivos de minimizar los retardos y maximizar la correlación. Fuente: Elaboración propia, 2017.

Consecuentemente para cada individuo se obtuvo el conjunto de modelos que conforman el frente de Pareto y el conjunto de modelos dominados.

4.2.1. Comportamiento del costo ante la calidad

Al analizar las gráficas en 3 dimensiones se encontraron resultados muy interesantes, principalmente respecto al costo y su nivel efecto sobre la calidad del modelo. Lo que conllevó a realizar un análisis de costo – calidad completo contra el resto de las variables (*i.e.* nu, correlación, total de retardos y vectores de soporte) para analizar su comportamiento y ver cuál es la inferencia significativa.

La forma de evaluación fue una inspección visual de la variable costo ante la calidad en gráficos de 3 dimensiones donde 2 dimensiones fijas corresponden al Costo y la calidad definida para este estudio y la dimensión restante corresponde a cada una de las otras variables en estudio.

Cabe hacer notar la importancia de la evaluación, ya que uno de los objetivos primordiales del estudio era analizar si existían diferencias importantes en los resultados obtenidos por los modelos y, la variable costo tiene una relación intrínseca con la cantidad de modelos y los tiempos de procesamiento de las SVM. Este análisis también contribuye a la idea de que no es altamente significativo utilizar una gama extensa de costos, ya sean lineales o exponenciales.

Los valores fueron promediados y agrupados para todos los individuos, obteniendo así resultados representativos del total de las muestras. Las gráficas se obtuvieron para los valores ARI y mfARI individualmente.

El comportamiento observado para todos los casos es de interés, ya que si se toma en consideración la variable calidad se observa que independiente del costo utilizado para evaluar cada modelo, el puntaje de calidad tiende a ser constante.

A continuación (figuras 4-3, 4-4, 4-5 y 4-6) se presentan las gráficas de 3 dimensiones donde el color de cada punto indica el nivel de calidad del modelo y en el eje de las abscisas se sitúa la variable C.




FIGURA 4.2.1-1: Gráfica de 3 dimensiones (Correlación-Costo Exponencial-Calidad mfARI) para todos los sujetos. Fuente: Elaboración propia, 2017.





FIGURA 4.2.1-2: Gráfica de 3 dimensiones (NU-Costo Exponencial-Calidad mfARI) para todos los sujetos. Fuente: Elaboración propia, 2017.



4.3. FRENTE DE PARETO

Para poder utilizar el frente de Pareto como conjunto representativo del total de modelos, se hace necesario realizar una comparación con el conjunto de modelos dominados y analizar si estadísticamente tienen la misma validez. Para esto se observó la similitud entre ambas muestras. La forma apropiada escogida para analizar la similitud de los conjuntos es observar el comportamiento de la varianza en los conjuntos.

En primera instancia se realizó la obtención del frente de Pareto considerando las 5 dimensiones: Nu – Costo – Correlación – Retardos – N° de Vectores Soporte. Esto conllevó al análisis mediante el uso de un test ANOVA de 3 vías: Modelo – Conjunto – Índice. Como ambos conjuntos constan de varios modelos y lo que se está intentando observar es el comportamiento general, los valores fueron promediados, estableciendo así un solo valor, por modelo, para cada uno de los 16 sujetos del estudio.

4.3.1. Validación del Frente de Pareto respecto a índices ARI-mfARI

Los resultados del contraste entre el conjunto frente de Pareto y el conjunto dominado se pueden ver en la tabla 4-3, e indican que a excepción del modelo FIR, todos los valores p son mayor a 0,05 lo que indica similaridad en ambos conjuntos. Esto es ideal ya que se está corroborando el hecho de que utilizar el conjunto frente de Pareto es igual de representativo que utilizar la totalidad de los modelos como espacio muestral. La excepción no es relevante para el estudio ya que implica diferencias significativas en el método de aprendizaje de menor nivel utilizado en los entrenamientos.

TABLA 4.3.1-1: Resultados de contraste Pareto-Dominado en ANOVA de 3 vías para índices de calidad mfARI.

Modelo	Error Estándar	Grados de libertad	Valor- p
FIR	0.18	145.8	<.001
NFIR	0.18	145.8	0.702
ARX	0.18	145.8	1.000
NARX	0.18	145.8	0.508

4.3.2. Análisis de la calidad en frente de Pareto

Los resultados obtenidos en el frente de Pareto de 5 factores dieron como promedio, para cada aprendizaje, valores que en términos de calidad presentaron un comportamiento diferente al esperado (los aprendizajes de impulsos finitos presentaron mayor calidad que los regresivos, tabla 4-4), por lo que se hizo necesario abordar todas las combinaciones posibles como frente de Pareto.

Se obtuvieron todos los frentes de Pareto considerando todas las combinaciones de factores como se puede ver en la tabla 4-4, donde la **X** significa que el factor fue considerado.

Los resultados de los promedios de calidad para cada método de aprendizaje muestran que se repite el comportamiento en que los aprendizajes FIR y NFIR poseen mayor calidad que los ARX y NARX.

TABLA 4.3.2-1: Combinaciones posibles de factores para el frente de Pareto con sus respectivos promedios de calidad para cada método de aprendizaje.

Retardos	Correlación	Costo	N° Vectores	Nu	Promedios Calidad			
					FIR	ARX	NFIR	NARX
X	X	X	X	X	8,4	5,8	8,2	6,2
X	-	X	X	X	7,9	5,9	8,0	5,8
X	X	-	X	X	8,6	5,8	8,1	6,0
X	X	X	X	-	8,4	5,8	8,2	6,2
-	X	X	X	X	8,7	5,8	8,4	6,3
X	X	X	-	X	8,3	5,8	8,2	6,3
X	X	-	-	-	8,7	5,8	8,3	6,1
X	-	X	-	-	7,1	5,8	7,7	5,9
-	X	X	-	-	8,8	5,7	8,4	6,3
X	-	-	-	X	7,9	5,9	7,3	6,1
-	X	-	-	X	8,7	5,8	8,3	6,2
-	-	X	-	X	8,5	6,0	8,4	6,0
X	-	-	X	-	7,6	5,9	7,2	5,8
-	X	-	X	-	8,8	5,8	8,4	6,0
-	-	X	X	-	8,4	6,2	8,3	6,0
-	-	-	X	X	8,2	6,1	8,2	6,1
X	X	X	-	-	8,4	5,8	8,3	6,4
X	X	-	-	X	8,6	5,8	8,0	6,1
X	-	X	-	X	7,9	5,8	7,9	5,8
-	X	X	-	X	8,7	5,8	8,5	6,4
X	X	-	X	-	8,6	5,8	8,1	6,0
X	-	X	X	-	7,9	5,9	8,0	5,8
-	X	X	X	-	8,7	5,8	8,4	6,3
X	-	-	X	X	7,6	5,9	7,2	5,8
-	X	-	X	X	8,8	5,8	8,4	6,0
-	-	X	X	X	8,4	6,2	8,3	6,0

Las combinaciones que presentaron mejor y peor calidad para cada aprendizaje se pueden ver en la tabla 4-5. De estas, las mejores fueron escogidas para ser analizadas y comparadas con el frente de Pareto de 5 dimensiones.

De los factores se observa que para los aprendizajes lineales el factor Nu es optativo cuando la calidad es mayor, mientras que para los no lineales esto ocurre cuando la calidad es la más baja. Por otra parte se puede ver que los aprendizajes no lineales tienen los mismos factores en términos de calidad. Finalmente se observa que en todos los casos de calidad más alta el factor retardo fue descartado del frente de Pareto, lo que apunta al hecho de que el total de los retardos no es un buen indicador de buenos modelos.

TABLA 4.3.2-2: Calidad máxima y mínima para cada modelo de aprendizaje con sus respectivos factores del frente de Pareto.

Modelo	Calidad	Valor	Factores Pareto
FIR	Máxima	8,756	Vectores de Soporte – Correlación – (Nu)
FIR	Mínima	7,125	Costo - Retardos
ARX	Máxima	6,150	Vectores de Soporte – Costo – (Nu)
ARX	Mínima	5,719	Costo - Correlación
NFIR	Máxima	8,456	Costo – Correlación - Nu
NFIR	Mínima	7,213	Vectores de Soporte – Retardos – (Nu)
NARX	Máxima	6,388	Costo – Correlación - Nu
NARX	Mínima	5,763	Vectores de Soporte – Retardos – (Nu)

Nuevamente es necesario comparar la validez del conjunto frente de Pareto contra dominados, para observar el comportamiento de la calidad. Los resultados obtenidos se encuentran en la tabla 4-6. Se observa que hay una mejora en términos calidad, por lo que resulta mejor no utilizar las 5 dimensiones definidas en primera instancia.

TABLA 4.3.2-3: Variación en términos de calidad al cambiar los factores del frente de Pareto.

	FIR	ARX	NFIR	NARX	Promedio
Pareto de 5 factores	8,388	5,806	8,213	6,213	7,155
Pareto de 4 => factores	8,756	6,150	8,456	6,388	7,438

Para darle validez a los resultados es importante la evaluación de la similaridad de los conjuntos con su correspondiente ANOVA de 3 vías considerando los nuevos conjuntos. Los resultados son reveladores como se puede ver en la tabla 4-7, donde se ve que no existen diferencias significativas.

TABLA 4.3.2-4: Resultados de contraste Pareto-Dominado en ANOVA de 3 vías para índices de calidad mfARI en Pareto de 4 o menos factores.

Modelo	Error Estándar	Grados de libertad	Valor- <i>p</i>
FIR	0.21	158.7	0.501
NFIR	0.21	158.7	0.412
ARX	0.21	158.7	0.108
NARX	0.21	158.7	0.170

4.3.3. Aplicación de las reglas de asociación

De estos resultados se pudo decidir qué factores considerar en cada aprendizaje para la obtención del frente de Pareto, pero como el foco del estudio es la calidad, se aplicaron reglas de asociación para tratar de encontrar comportamientos asociados a la mejor calidad de las señales.

4-8 categorizaron las variables de forma que se puedan agrupar los resultados. En la tabla 14 se puede ver como se categorizó la calidad ya que se utilizó como lado derecho de las reglas de asociación.

TABLA 4.3.3-1: Categorías utilizadas para la calidad de las señales.

Valor Calidad	Categorización Calidad
(0 , 5]	Baja
(5 , 7.5]	Normal
(7.5 , 9]	Alta
(9 ,10]	Muy Alta

Las reglas fueron obtenidas con un soporte de 0,25 y una confianza 0,1 ya que dada la cantidad de modelos por cada aprendizaje estos valores son representativos para el estudio. La totalidad de las reglas encontradas para cada tipo de entrenamiento se pueden ver en el apéndice C, en las tablas 4-9, 4-10, 4-11 y 4-12 se pueden observar las reglas que se escogieron para ser aplicadas sobre el frente de Pareto para la posterior elección de un modelo.

TABLA 4.3.3-2: Reglas de asociación para modelo de aprendizaje FIR con soporte = 0,25 y confianza = 0,1.

Cantidad	Transacción	Soporte	Confianza	Mejora de la confianza
48	{CORR=(0.5,0.75]} => {CALIDAD=MUY ALTA}	0,302	0,565	1,425
46	{RET=(5,10]} => {CALIDAD=ALTA}	0,289	0,590	1,116

TABLA 4.3.3-3: Reglas de asociación para modelo de aprendizaje ARX con soporte = 0,25 y confianza = 0,1.

Cantidad	Transacción	Soporte	Confianza	Mejora de la confianza
810	{nu=0.1} => {CALIDAD=NORMAL}	0,58	0,599	1,033
810	{VS=(0,50]} => {CALIDAD=NORMAL}	0,58	0,580	1,000
810	{COSTO=(0,32]} => {CALIDAD=NORMAL}	0,58	0,580	1,000
810	{VS=(0,50],nu=0.1} => {CALIDAD=NORMAL}	0,58	0,599	1,033
810	{nu=0.1,COSTO=(0,32]} => {CALIDAD=NORMAL}	0,58	0,599	1,033
810	{VS=(0,50],COSTO=(0,32]} => {CALIDAD=NORMAL}	0,58	0,580	1,000
810	{VS=(0,50],nu=0.1, COSTO=(0,32]} => {CALIDAD=NORMAL}	0,58	0,599	1,033

TABLA 4.3.3-4: Reglas de asociación para modelo de aprendizaje NFIR con soporte = 0,25 y confianza = 0,1.

Cantidad	Transacción	Soporte	Confianza	Mejora de la confianza
130	{COSTO=(0,32]} => {CALIDAD=MUY ALTA}	0,281	0,414	1,065
125	{COSTO=(0,32]} => {CALIDAD=ALTA}	0,270	0,398	0,975

TABLA 4.3.3-5: Reglas de asociación para modelo de aprendizaje NARX con soporte = 0,25 y confianza = 0,1.

Cantidad	Transacción	Soporte	Confianza	Mejora de la confianza
1642	{CORR=(0.75,1]} => {CALIDAD=NORMAL}	0,700	0,700	1,000
948	{RET=(5,10]} => {CALIDAD=NORMAL}	0,404	0,776	1,110
948	{CORR=(0.75,1],RET=(5,10]} => {CALIDAD=NORMAL}	0,404	0,776	1,110

De esta forma se obtiene un nuevo conjunto acotado del frente de Pareto, el cual corresponde a la refinación en base a las reglas escogidas. Los nuevos resultados son procesados nuevamente en un ANOVA de 3 vías para entender si existen diferencias significativas entre el nuevo frente de Pareto y su conjunto dominado. Los resultados se pueden ver en la tabla 4-13 y se aprecia que no existen diferencias significativas para ningún tipo de aprendizaje.

TABLA 4.3.3-6: Resultado de test ANOVA de 3 vías para validez del conjunto frente de Pareto.

Modelo	Error Estándar	Grados de libertad	Valor - p
FIR	0.21	158.9	0.5004
NFIR	0.21	158.9	0.4122
ARX	0.21	158.9	0.1083
NARX	0.21	158.9	0.1695

Lo más relevante de estos resultados es que no hay variación si se compara con el análisis ANOVA del frente de Pareto de 4 factores o menos. Esto indica que el aplicar las reglas de asociación no define una mejora en la calidad promedio de los modelos. En la tabla 4-14 se puede ver el promedio de la calidad por aprendizaje de los frentes de Pareto a medida que se fue refinando el estudio.

El paso de 5 factores a 4 factores (o menos) presenta una leve mejoría, pero ya cuando se aplican las reglas de asociación no hay mejora en ninguno de los aprendizajes.

TABLA 4.3.3-7: Mejora de la calidad al cambiar foco del frente de Pareto.

	FIR	ARX	NFIR	NARX	Promedio
Pareto de 5 factores	8,388	5,806	8,213	6,213	7,155
Pareto de 4 => factores	8,756	6,150	8,456	6,388	7,438
Reglas de asociación aplicadas	8,756	6,150	8,456	6,388	7,438

Finalmente se obtuvo un conjunto de frente de Pareto para cada individuo, por lo que se procede a promediar los índices de autorregulación ya que cada modelo del conjunto corresponde a un óptimo para los múltiples objetivos. De esta forma se obtienen valores representativos sobre los cuales se obtiene la calidad de cada individuo.

Por otra parte también se tienen los modelos escogidos en el estudio de Miranda (2016), siendo la base de estudio la misma se le pudo aplicar el análisis de calidad, por lo que es posible comparar ambos enfoques nuevamente con un ANOVA de 3 vías. En la tabla 4-15 se ven los promedios de la calidad para ambos estudios.

TABLA 4.3.3-8: Índices de calidad para frente de Pareto y estudio de filtro avanzado.

Régimen	Índice	FIR	NFIR	ARX	NARX
Pareto	Calidad mfARI	8,9 ± 0,81	8,9 ± 0,83	6,2 ± 0,99	6,4 ± 0,89
Filtro avanzado	Calidad mfARI	9,1 ± 0,60	8,7 ± 1,25	8,8 ± 1,71	8,2 ± 1,66

Existe gran similitud entre los modelos FIR y NFIR, mientras que para los aprendizajes regresivos el frente de Pareto posee un factor de calidad considerablemente menor.

Similitud de los conjuntos de estudio

Dentro de este análisis comparativo se hace necesario entender si los modelos escogidos por el estudio del filtro básico (Miranda, 2016) se encuentran presentes dentro del frente de Pareto. Los resultados son reveladores y se pueden observar en la tabla 4-16. En ella se puede ver como los modelos escogidos por el filtro no se encuentran en el frente de Pareto, demostrando que el frente de Pareto referencia a un conjunto acotado que presenta resultados significativamente iguales pero son completamente independientes. Esto sucede ya que los elementos del frente de Pareto (al igual que los del filtro básico) también buscan los elementos de más alta correlación, además de los otros factores de optimización, entregando un enfoque selectivo de mayor precisión, ya que considerar solamente la correlación como un factor único puede llevar a seleccionar un modelo sobreentrenado o más complejo teniendo la opción de escoger uno de mayor simpleza.

Otra diferencia es que el volumen del conjunto solución en el filtro básico puede ser significativamente mayor, ya que se puede dar el caso de que exista una gran cantidad de modelos con una correlación alta e igual, en cambio en el frente de Pareto los volúmenes son acotados y la importancia de los modelos recae en la significancia de cada factor dado por el enfoque de estudio.

TABLA 4.3.3-9: Presencia de modelo escogido a través del filtro avanzado en frente de Pareto.

Sujeto	FIR	NFIR	ARX	NARX
1	No	No	No	No
2	No	No	No	No
3	No	No	No	No
4	No	No	No	No
5	No	No	No	No
6	No	No	No	No
7	No	No	No	No
8	No	No	No	No

Sujeto	FIR	NFIR	ARX	NARX
9	No	No	No	No
10	No	No	No	No
11	No	No	No	No
12	No	No	No	No
13	No	No	No	No
14	No	No	No	No
15	No	No	No	No
16	No	No	No	No

4.4. EFICIENCIA DE LOS MODELOS

En la siguiente sección se analizará los resultados de las métricas para entender el grado de aprendizaje alcanzado por los modelos. Cabe hacer notar que cada modelo fue en primera instancia entrenado y posteriormente validado, por lo que se analizaron las correlaciones para ambos. Los resultados **promediados** se pueden ver en la tabla 4-17 en donde se observa que el modelo NARX posee el más alto rendimiento con una correlación de valor $0,973 \pm 0,031$.

TABLA 4.4-1: Eficiencia promedio modelos, Fuente: Elaboración propia, 2017.

Modelo	CC	
	Entrenamiento	Validación
FIR	$0,658 \pm 0,129$	$0,643 \pm 0,154$
NFIR	$0,690 \pm 0,100$	$0,605 \pm 0,184$
ARX	$0,945 \pm 0,041$	$0,850 \pm 0,056$
NARX	$0,972 \pm 0,030$	$0,973 \pm 0,031$

4.5. ÍNDICES AUTORREGULATORIOS DE LOS MODELOS

A continuación se pueden observar los promedios de los índices autorregulatorios para cada modelo de entrenamiento, los cuales fueron comparados con su equivalente para el estudio del filtro avanzado (Miranda, 2016). Cada promedio aparece acompañado de su respectiva desviación estándar. El detalle de los índices autorregulatorios por individuo puede apreciarse en el APÉNDICE A.

En la tabla 4-18 se puede observar como los índices autorregulatorios son inferiores en el frente de Pareto.

TABLA 4.5-1: Valores promedios de los índices de autorregulación. Fuente: Elaboración propia, 2017.

Régimen	Índice	FIR	NFIR	ARX	NARX
Pareto	mfARI	$5,2 \pm 1,60$	$5,5 \pm 1,30$	$1,7 \pm 0,45$	$2,0 \pm 0,82$
	ARI	$4,6 \pm 2,26$	$4,4 \pm 1,26$	$1,9 \pm 0,60$	$1,7 \pm 0,75$
Filtro Avanzado	mfARI	$6,0 \pm 1,02$	$6,4 \pm 1,60$	$5,7 \pm 1,53$	$6,1 \pm 2,18$
	ARI	$4,7 \pm 1,63$	$5,2 \pm 2,03$	$4,6 \pm 1,53$	$5,2 \pm 2,33$

Se observa como los índices FIR y NFIR poseen similitud en el frente de Pareto y el filtro avanzado. Esto no ocurre en los modelos regresivos, es más, en el frente de Pareto son mucho menores en magnitud. Se subentiende que el frente de Pareto discrimina mejor con los modelos de respuesta al impulso finito.

Pero para observar la verdadera diferencia entre ambos enfoques se hizo necesario realizar un contraste para estudiar la semejanza (tabla 4-19). Esto se realizó mediante otro test ANOVA de 3 vías: considerando el tipo de estudio, el modelo utilizado y el índice.

TABLA 4.5-2: Resultados de test ANOVA de 3 vías para filtro avanzado y frente de Pareto, Fuente: Elaboración propia, (2017).

Modelo	Índice	Grados de libertad	Valor- p
ARX	ARI	130.5	0.010
FIR	ARI	130.5	0.001
NARX	ARI	130.5	0.031
NFIR	ARI	130.5	0.003
ARX	mfARI	130.5	0.669
FIR	mfARI	130.5	0.319
NARX	mfARI	130.5	<.001
NFIR	mfARI	130.5	<.001

Como resultado se observa que los únicos modelo que son significativamente iguales son ARX y FIR para el mfARI. Para los modelos no lineales del índice mfARI se obtienen los estadísticos más bajos, esto denota una diferencia de magnitud la cual podría deberse al uso de los retardos en el flujo.

Los modelos de impulsos finitos son los de valor p más bajo para el índice ARI, mientras que los regresivos igual poseen diferencias significativas.

CAPÍTULO 5. DISCUSIÓN

A continuación se explica los resultados obtenidos en el capítulo anterior. En primera instancia se analiza el contraste entre el aprendizaje obtenido con un costo del tipo lineal y un costo exponencial, principalmente para observar si existen diferencias. Posteriormente se revisa el frente de Pareto a través del análisis de su obtención y los análisis de sus correspondientes validaciones. Siguiendo el análisis de Pareto, se realiza la comparación con el filtro avanzado, para finalizar el capítulo con las observaciones de la eficiencia del frente de Pareto y los índices autorregulatorios obtenidos por este.

5.1. ANÁLISIS CONTRASTE EXPONENCIAL – LINEAL

El análisis exponencial – lineal constó del aprendizaje de las SVM para las mismas señales pero con diferentes costos. Esto produjo diferentes resultados para cada modelo entrenado.

Para el costo exponencial, el conjunto de índices ARI presentó un valor— p de 0,437, lo que indica que sí existe normalidad en esa población. Mientras que para el caso de los mfARI el valor— p alcanza un 0,098, indicando también que se trata de una población que proviene de una distribución normal.

Para el caso del costo lineal los índices ARI entregaron un valor— p igual a 0,345, mientras que para los mfARI el valor— p fue 0,224, siendo estos resultados $>,05$ implica que para ambos casos se está en presencia de conjuntos normales.

El resultado del *t-test* para los ARI fue de un valor— p igual a 0,720, en cambio el de los mfARI fue igual a 0,909, siendo ambos casos $>,05$ se acepta la hipótesis nula de que los conjuntos son iguales.

Estos resultados indican que ambos costos no presentan diferencias significativas, por ende se entiende que el aprendizaje realizado utilizando cualquiera de los dos costos definidos es similar, por lo que se procedió a continuar con el estudio solo utilizando el costo exponencial, el cual es el utilizado comúnmente en los estudios previos de este tipo, e.g. Miranda (2016).

5.2. ANÁLISIS PUNTAJES DEL FILTRO AVANZADO

Los puntajes que entrega el filtro avanzado fueron obtenidos en base al procesamiento de los 100 primeros modelos (válidos, dadas las condiciones básicas entregadas en la sección 3.4.2) de mayor correlación. Estos resultados se sesgaron arbitrariamente al puntaje 10, esto dado que las correlaciones podrían corresponder a modelos que sobre-aprendieron el

comportamiento original de la señal. Este comportamiento fue observado en la mayoría de los modelos de aprendizaje.

Por este motivo el factor puntaje fue descartado como factor del análisis de Pareto. Se procedió a analizar el frente de Pareto con la idea original, esto es, los factores correlación, nu, costo, total de retardos y número de vectores de soporte.

Ya con esta definición se procedió a hacer una primera inspección visual para observar si existía algún comportamiento.

Esto se realizó generando todas las combinaciones de 2 dimensiones para los factores del frente de Pareto y coloreando cada vértice en base a una gama de colores que representaba el valor de la calidad. Los valores de las calidades fueron promediados respecto al agrupamiento de las variables en cuestión para cada gráfica.

De todas las gráficas procesadas se encontró un comportamiento notable respecto al costo. El costo evaluado contra cada factor del frente de Pareto poseía mayoritariamente, en cada nivel del factor, un valor de calidad aproximado igual o muy similar. A pesar de que no se encontró ninguna tendencia creciente o decreciente, si se observó que existe una neutralidad del costo respecto al nivel del factor que sea evaluado.

Esto indica que, si se escoge un valor fijo para alguna de las variables utilizadas en el entrenamiento (dentro de las variables nu, total de retardos, número de vectores de soporte o correlación) el valor de la calidad será el mismo para cualquier costo. Esto es óptimo ya que indica que se puede utilizar siempre el menor costo y evitar tener que buscar o entrenar modelos de un alto costo, ganando tiempo de procesamiento. **Esto es fácil de observar ya que bastaría con escoger un hiperparámetro C fijo y no tener que utilizar la gama completa de costos, lo que reducirá la cantidad de modelos procesados en el orden de los miles.**

5.3. ANÁLISIS DEL FRENTE DE PARETO

Con el algoritmo desarrollado, se procedió obteniendo el frente de Pareto para los 5 factores (nu, costo, correlación, número de vectores de soporte y total de retardos) para cada individuo en cada modelo de aprendizaje. Esto redujo la cantidad de modelos de cada individuo de forma considerable, desde 13000 o más hasta 200 modelos aproximadamente. El frente de Pareto representa a un conjunto óptimo con los 5 factores como funciones a optimizar.

Luego se comprobó la validez del conjunto de Pareto respecto al resto de modelos mediante un ANOVA de 3 vías. Para esto las calidades de ambos conjuntos fueron promediadas por individuo. Las vías escogidas fueron el índice del modelo, el conjunto y el modelo mismo. El contraste arrojó que, **tal como se puede ver en la tabla 4-3**, para los casos de NARX, NFIR y ARX no existe diferencia significativa entre los conjuntos frente de Pareto y modelos dominados. Mientras que el caso del modelo FIR, el contraste indicó que existía un valor $-p < .001$ lo que indica que para ese tipo de aprendizaje específico si existían diferencias significativas, pero

considerando que este es el de más bajo nivel (en términos de parámetros y funcionamiento) este resultado fue irrelevante. Por lo tanto se validó y aceptó de forma correcta que el frente de Pareto si representa a la totalidad de modelos dado el tipo entrenamiento y la totalidad de modelos entrenados.

Con los 5 factores utilizados en función de la calidad, el foco era la obtención de la mejor calidad. Por lo tanto, se calculó el promedio de la misma para todos los individuos en cada modelo de aprendizaje. El objetivo era poder observar si existía algún patrón o comportamiento en los resultados. Lo que se encontró a grandes rasgos fueron 2 comportamientos:

1. Los entrenamientos **dados por las estructuras del tipo FIR entregaban mayor calidad que las estructuras** del tipo regresivo.
2. En general las calidades eran muy bajas.

Como el objetivo del estudio es analizar la calidad, se realizó nuevamente la obtención del frente de Pareto, pero esta vez contemplando todas las combinaciones posibles de los factores, incluyendo solo 4, 3 o 2 factores. De esta forma se volvió a repetir el proceso de los promedios de la calidad por individuo en cada tipo de aprendizaje.

Para los FIR los resultados demostraron que se pueden encontrar mejores resultados utilizando los factores correlación y número de vectores de soporte con una calidad de 8.8 sobre un promedio de 8.3. Aquí la utilización del factor nu es opcional ya que con y sin el factor **nu** se obtuvo la mejor calidad.

Para los ARX la calidad más alta está en 6,2 sobre un promedio de 5,9 con los factores número de vectores de soporte y costo. Para los NFIR el valor de la calidad más alta está en 8,5 sobre un promedio de 8,1 usando el costo, la correlación y el nu. Para el aprendizaje NARX la situación es la misma: la calidad más alta se encuentra utilizando nuevamente el costo, la correlación y el nu, a un valor de calidad 6,4 sobre 6,0 promedio.

De los factores utilizados en cada tipo de aprendizaje, ningún caso hace referencia al total de retardos. Esto implica que el uso de los retardos conlleva una baja en la calidad, que aunque puede no ser extremadamente baja, si se decrementa la calidad, que es lo que se desea optimizar a grandes rasgos. Al analizar los individuos uno por uno se observó que los retardos que más influían en la baja de calidad eran los de un bajo retardo asociado a un alto costo.

Luego para evaluar estas conjeturas se compararon las calidades (por tipo de entrenamiento y el promedio de estas) del frente de Pareto de 5 factores *versus* los frentes de Pareto escogidos por tener la más alta calidad. Los resultados dieron que en promedio los de 5 factores poseen una calidad de 7,135 mientras que los de 4 o menos factores poseen una calidad promedio de 7,438 denotando una ganancia en calidad al especificar el frente de Pareto. De igual forma se observó que ningún tipo de entrenamiento se mantuvo o empeoró respecto a la calidad, todos aumentaron, no de forma considerable pero si efectiva.

Se entiende entonces, que la mejor calidad no se encuentra en el uso del frente de Pareto con todos los factores considerados. Dependiendo del tipo del estudio conviene utilizar distintos enfoques.

Nuevamente hubo que validar los conjuntos frente de Pareto y conjunto de modelos dominados con un test estadístico ANOVA de 3 vías, pero esta vez sobre los nuevos conjuntos conformados después de obtener los frentes de Pareto de 4 o menos factores. Los resultados fueron todos con un valor $-p > ,05$, con FIR igual 0,501, NFIR igual a 0,412, ARX igual a 0,108 y NARX igual a 0,170. Estos resultados indicaron que los conjuntos son similares y por lo tanto los nuevos frente de Pareto si son representativos de todo el universo de modelos procesados.

Finalmente con los conjuntos ya acotados por el frente de Pareto se procedió a aplicar minería de datos. Se le identificaron reglas de asociación con un soporte igual a 0,3 y una confianza de 0,1 (siendo los de esta magnitud los más frecuentes y confiables ya que la variabilidad de los modelos es muy alta) como las más interesantes. Esto porque el nuevo objetivo era acotar aún más el conjunto del frente de Pareto e identificar patrones o comportamientos que explicaran la selección de parámetros válidos para el frente de Pareto.

Para esto las variables fueron asignadas a rangos que permitieran encontrar asociaciones, siendo la más relevante el *Rank* de la variable de interés, que es la calidad. Esto permitió observar comportamientos y seleccionar aquellas reglas que implicaran un mayor soporte y a la vez obtuvieran los resultados de la asociación como la calidad más alta posible.

Con todas las reglas existentes identificadas se volvió a filtrar cada frente de Pareto, donde en resumidas cuentas se observó que no hubo ganancia ni pérdida en ningún sentido de la calidad, esto porque las reglas de asociación no fueron lo suficientemente influyentes como para decidir acotar aún más el conjunto. Para validar esto mismo se obtuvo el promedio de las calidades de los individuos de la misma forma que se validaron los frentes de Pareto con menos factores. Los resultados fueron netamente que no hubo ganancia respecto a la calidad. El valor promedio de la calidad entre los cuatro tipos de aprendizaje se mantuvo en 7,438, siendo que individualmente los valores se mantuvieron exactamente igual.

5.4. ANÁLISIS DE LA CALIDAD PARETO – FILTRO AVANZADO

Finalmente se obtuvieron los promedios de los índices de calidad para compararlos con los índices de calidad del estudio del filtro avanzado. Los resultados mostraron valores muy parecidos dependiendo del modelo de aprendizaje a considerar. Para los FIR los valores fueron semejantes, siendo el promedio de la calidad del frente de Pareto 8,9 mientras que para el filtro avanzado se obtuvo 9,1. Para los NFIR se obtuvo que la calidad del frente de Pareto es de 8,9, por otro lado en el filtro avanzado el valor es de 8,7 donde se puede ver nuevamente que existe gran semejanza en los valores. Es curioso que haya gran similitud en los aprendizajes FIR y NFIR para ambos casos, ya que los modelos del frente de Pareto corresponden a valores

totalmente diferentes de los vistos en el filtro avanzado, esto porque poseen retardos muy bajos, a diferencia del filtro donde aparecen con retardos muy altos.

Por otra parte, los valores promedio de la calidad son mucho menores en el frente de Pareto que en el filtro, para los aprendizajes ARX y NARX. Esto se puede ver ya que para ARX Pareto el valor fue 6,15 mientras que el valor del filtro fue 8,8. Por el lado de los NARX, en Pareto se obtuvo 6,4 y en el filtro 8,2.

Fuera del aprendizaje FIR, la calidad se ve mejor en el filtro avanzado, pero de igual forma la calidad Pareto FIR tiene tan solo una diferencia de dos décimas, además el aprendizaje FIR es el que posee el menor nivel respecto a los modelos de aprendizaje.

Un hito a considerar es que se buscaron los modelos escogidos por el filtro avanzado y ninguno de ellos se encontraba presente en los frentes de Pareto obtenidos. Esto puede deberse a que el filtro sesga a la correlación más alta, siendo que Pareto sesga a obtener los modelos que se encuentran más a los extremos de los datos, no necesariamente donde se concentran las más altas correlaciones.

En síntesis se observa una menor calidad en el frente de Pareto aunque en modelos de impulsos finitos es muy parecida. Esta superioridad del filtro avanzado respecto a la calidad podría indicar que no existe una correlación directa entre los valores de la calidad de las señales y la correlación de cada muestra. De igual forma cabe hacer notar, que solo la correlación de las señales no necesariamente implica ser un mejor indicador ya que una alta correlación también puede hacer referencia a un sobre-aprendizaje del modelo. Pero de igual forma el frente de Pareto contempla a los de mejor correlación por lo tanto ya acota el espacio muestral, obteniendo una mejora del filtro avanzado.

5.5. ANÁLISIS DE LA EFICIENCIA DEL FRENTE DE PARETO

De los resultados de la eficiencia de los modelos se observó que tal como se esperaba el mejor rendimiento lo entregó el aprendizaje NARX con un promedio de correlación equivalente a 0.973 con una desviación estándar baja, lo que indica la homogeneidad de los datos obtenidos. Esto puede interpretarse como un sobre-aprendizaje del entrenamiento pero se debe a que el frente de Pareto tiene como una de sus funciones objetivos maximizar la correlación, lo que conduce a estos resultados. Este rendimiento se corrobora observando que de los resultados del entrenamiento, el que posee la mayor correlación también es el aprendizaje NARX.

El caso de los ARX poseen también un rendimiento alto, con un valor de 0,945 lo que indica su buen comportamiento al momento de analizar el conjunto acotado del frente de Pareto en entrenamiento y validación. Por otro lado, los modelos de impulsos finitos (FIR y NFIR) no poseen un alto rendimiento ni en entrenamiento ni en validación. Los valores fueron 0,643 y 0,605 correspondientemente, con una desviación estándar que supera los 0,15 puntos. Se observó

también que estos últimos aprendizajes entregaron un rendimiento muy bajo, cercano al 50%, lo que indica que el frente de Pareto no es muy efectivo para entrenar con impulsos finitos.

Esto da la idea de que en el frente de Pareto, la correlación funciona de manera inversa respecto a la calidad, ya que como se puede ver en la sección 5.4 los resultados indican que los modelos regresivos dan peor calidad, totalmente diferente al comportamiento de la correlación.

5.6. ANÁLISIS DE LOS ÍNDICES AUTORREGULATORIOS

En los índices autorregulatorios se observa un comportamiento muy similar al ocurrido con los índices de calidad para ambos estudios. Esto tiene lógica ya que ambos análisis se basan en los mismos índices.

Se puede apreciar entonces como para los índices ARI los valores en los impulsos finitos (lineal y no lineal) son muy semejantes, varían hasta 8 décimas de diferencia en el índice, con una desviación estándar de no más de la unidad decimal. Mientras que las estructuras regresivas presentan diferencias de más de 3 puntos en el índice, lo que apunta a una baja precisión en la medición del índice con el frente de Pareto versus el filtro avanzado. Esto indica la relevancia de la simplicidad al momento de seleccionar los modelos, ya que los retardos como factor en los aprendizajes regresivos son el principal factor que se ve afectado por el tipo de estructura regresivo. De esta forma se tiene que el frente de Pareto si disminuye el espacio muestral pero sin embargo en las estructuras regresivas se requiere una mayor variedad de este mismo conjunto.

Para el caso de los índices mfARI se observa que todas las estructuras poseen un mejor rendimiento, siendo esta diferencia mayormente marcada nuevamente en los modelos regresivos. Al ser un índice que parte de la base de un modelamiento no lineal se sabe que presenta mayor especificidad respecto a los valores que obtiene, esto puede tener relación directa con la poca cantidad de modelos presentes en el frente de Pareto, dejando a la mayoría de modelos en el conjunto de los dominados. Obviamente estos conjuntos fueron de niveles mucho menores en los aprendizajes de estructuras regresivas.

El test ANOVA corrobora estos resultados indicando que existe semejanza solo en los índices mfARI para las estructuras ARX y FIR. Esto demuestra que la gran diferencia que existe y marca la superioridad del filtro avanzado recae en la variabilidad dada por la totalidad de elementos, mientras que estos mismos elementos en el frente de Pareto puede que queden descartados.

Se observa también que de los tipos de estructuras restantes para ambos índices en ambos estudios poseen grandes diferencias dadas por el enfoque utilizado y la influencia de los factores utilizados como función objetivo.

Finalmente se entiende que es posible obtener modelos significativamente iguales en ambos estudios que representen el fenómeno de manera adecuada, que tengan un desempeño

igual o mejor en términos de simplicidad pero con un índice autorregulatorio notoriamente inferior. El filtro avanzado implica una mayor complejidad que el frente de Pareto, pero con un mejor rendimiento para capturar el fenómeno de la autorregulación.

CAPÍTULO 6. CONCLUSIONES

La importancia del estudio de la autorregulación cerebral (AC) en la ciencia corresponde a poder realizar pronósticos o tomar mejores elecciones al momento de realizar tratamientos sobre individuos con algún tipo de afección cerebral. La necesidad poder obtener un modelamiento que represente de mejor forma el comportamiento real es clave para poder realizar estudios coherentes y efectivos de la AC. Es por esta razón que se decidió realizar el estudio que permitió probar una nueva forma de abordar un paso de suma importancia, el cual es la selección del modelo que represente la AC del individuo, mediante el uso de técnicas de la ingeniería informática que no habían tenido precedentes.

Las señales fueron procesadas para la obtención de modelos usando el método de aprendizaje de las máquinas vector de soporte (y sus hiperparámetros) con las siguientes estructuras: *finite impulse response (FIR)*, *non linear finite impulse response (NFIR)*, *auto regressive with exogenous variable input (ARX)* and *non linear auto regressive with exogenous variable input (NARX)*. Cada modelo obtenido fue posteriormente evaluado en base un algoritmo que busca los mejores modelos en base a la optimización de cada una de las 5 variables definidas para el estudio como factores del frente de Pareto: Nu – costo – correlación – número de vectores de soporte y total de retardos utilizados. Estos modelos seleccionados conformaron el frente de Pareto, el cual corresponde al borde u óptimos globales del problema de optimización. De estos modelos seleccionados, se promediaron los resultados de *Auto Regulation Index (ARI)* y *model free Auto Regulation Index (mfARI)* para analizar las diferencias internas entre los conjuntos del frente de Pareto y conjunto dominado, y además se utilizaron estos resultados para compararlos con un estudio previo donde utilizaron un filtro avanzado para la selección del modelo (Miranda, 2016).

Por otra parte se le agregó el concepto de calidad el cual muestra la cercanía del modelo seleccionado hacia el modelo original realizado por el estudio de Mahony (2000), respecto del valor mfARI.

El objetivo fue cumplido casi a cabalidad, ya que se deseaba poder obtener los modelos y sus correspondientes resultados utilizando un nuevo enfoque de selección basado en los parámetros y la optimización de estos mismos. Los resultados no fueron los esperados, dado que no mostraban mejoras respecto a los índices obtenidos. El ideal hubiese sido poder encontrar índices de autorregulación con una mayor calidad y que tuvieran una mayor correlación, reflejando así la similitud del comportamiento autorregulativo.

Por otra parte quedó pendiente el poder realizar un análisis exhaustivo respecto al sistema de puntajes utilizado por el filtro avanzado ya que en el estudio previo (Miranda, 2016), los modelos seleccionados fueron los de más alto puntaje sesgando a la mayoría a un valor

máximo, lo cual no era viable de considerar como función objetivo para la optimización multi-objetivo.

En el caso del análisis de costos se observó cómo los resultados de ARI y los del mfARI no varían, independiente de la variable contra la que se esté midiendo, por lo que se infirió que para cualquier estudio de la AC, utilizar el costo exponencial o el lineal no altera los resultados en mayor magnitud, o de forma estadísticamente significativa, lo único que afecta es el tiempo de procesamiento.

Al analizar el comportamiento de los índices de calidad y el costo ante el resto de los factores se observó que dado el nivel del tercer factor no había variación de la calidad independiente del costo asociado, esto demuestra que el valor del costo utilizado no tiene influencia ante combinaciones fijas de los otros factores, lo que indica que posible realizar estudios con un costo fijo y obtener resultados estadísticamente significativos. Esto fue determinado utilizando la calidad de asociada de los modelos, pero es válido para los índices ARI y mfARI ya que la calidad es en función de estos valores.

Los resultados de los índices autorregulatorios fueron categóricos principalmente al recalcar que no existe semejanza ni relación alguna entre ambos estudios, demostrando que existe una diferencia entre utilizar factores con sus propias funciones objetivos o utilizar la correlación y un sistema de puntajes. El sistema de puntajes asociado a los modelos de mayor correlación presentan por lejos un mayor rendimiento al momento de capturar el fenómeno autorregulatorio, dejando a la optimización multi-objetivo como un método válido pero no efectivo si se utilizan 5 factores como los del presente estudio. Esto no implica que la optimización multi-objetivo sea una peor forma de evaluar los modelos, sino que al contrario, indica que es necesario realizar un análisis más exhaustivo al momento de escoger qué factores usar y qué función objetivo definir. Si se pudiesen encontrar estos parámetros de forma óptima es probable que se encuentren resultados que representen de mejor forma la AC, ya que la optimización multi-objetivo presenta gran variedad de valores con una muy alta calidad según se definió en este estudio, pero este trabajo quedará pendiente para futuros trabajos de investigación.

Por su parte, los modelos de aprendizaje con estructuras de impulsos finitos, en sus variantes lineal y no lineal, presentan un mejor rendimiento que los regresivos, esto se debe a que, apuntando al principio de la parsimonia, son menos complejos, con menos retardos, optimizando así los resultados.

El algoritmo de la optimización multi-objetivo es efectivo pero se debe ser cuidadoso al momento de escoger los factores, ya que dados los índices que se pretendan medir, los factores cumplen un rol determinante. Se observó que no es bueno considerar los retardos como factor para cualquier estudio que utilice este algoritmo, porque los modelos de estructuras regresivas consideraban retardos de la velocidad de flujo y para ambos índices (ARI y mfARI) esto disminuía la asertividad al momento de capturar el fenómeno. De la misma forma se observó también que

costos crecientes con altas correlaciones tienden a ir disminuyendo el factor calidad, pero el factor costo por sí solo no representa un efecto importante.

Utilizar las técnicas de reglas de asociación, no representan una mejora, ya que los conjuntos se encuentran lo suficientemente acotados y aún así existe una variabilidad bastante amplia en los modelos, **conllevando a reglas de asociación poco frecuentes.**

Análogamente al este estudio, se encontró que ninguno de los modelos obtenidos por el filtro avanzado se encuentran presentes en los conjuntos del frente de Pareto, lo que apunta a la variabilidad de los modelos dentro de un entrenamiento **al utilizar este último enfoque, lo que indica que una mayor variabilidad en el espacio muestral dispone modelos que poseen probablemente mejores rendimientos.** Además se observó que los modelos seleccionados por el frente de Pareto, dadas sus funciones objetivo, optimizan el total de retardos disminuyendo los índices de AC.

Sin embargo dadas estas conclusiones, cabe recalcar que existe mucho campo aún para el estudio de la optimización multi-objetivo como aplicación en el entrenamiento de señales biológicas. Se puede contemplar el uso de la obtención del frente de Pareto mediante la generación de algoritmos genéticos que posean como función objetivo las funciones de optimización. También dados los resultados obtenidos como frente de Pareto, queda pendiente el análisis de en qué parte del conjunto solución se encuentran repartidos los modelos del frente de Pareto, ya que éstos podrían estar definidos por alguna característica o comportamiento específico.

También queda abierta la idea de con qué tipo de modelo de aprendizaje se obtienen resultados mejores en términos de eficiencia, rendimiento e índices, ya que dadas las posibilidades con que pueden obtener frentes de Pareto, es relevante analizar si existen resultados significativamente mejores y en base a qué se comportan de esa manera.

Este estudio fue realizado sobre datos de pacientes totalmente sanos, por lo que un estudio de estas características sobre pacientes con afección queda pendiente para el campo de estudio y futuros trabajos, ya que otras patologías podrían mostrar resultados interesantes.

El último punto de importancia es que este es el inicio del enfoque multi-objetivo para el análisis de señales biológicas, donde si se logra aceptar la validez (aún quedan futuros trabajos para comprobar su validez, e.g. en pacientes enfermos) del frente de Pareto con resultados ideales entonces se estaría mejorando la *performance* de la búsqueda de señales óptimas, reduciendo los tiempos de diagnóstico y de tratamientos. Dada la variabilidad existente entre los sujetos de estudios se debe mencionar que los costos de análisis podrían ser creciente por lo tanto obtener alguna ganancia en términos de procesamiento y performance se vuelve algo necesario, he ahí la importancia de este estudio.

A modo científico, este estudio define la importancia de la correlación existente entre la señal de la variación espontánea y la señal obtenida a través del modelo de aprendizaje, ya que para tanto para el filtro avanzado como el técnicas de optimización multi-objetivo existe una alta

influencia de la correlación. Esto ocurre conjuntamente con la influencia de la cantidad de retardos utilizados en el entrenamiento, apuntando principalmente a que si se pudiese utilizar los modelos más simples disponibles entonces es primordial hacerlo, siguiendo el principio de parsimonia (navaja de Occam), ya que los resultados poseerían igual validez. Por otro lado los factores relativos a los hiperparámetros de las máquinas de vectores soporte no tienen una mayor participación ni colaboración en la simpleza y consistencia del estudio.

Este trabajo demuestra que es posible obtener mejoras de los procedimientos actuales para capturar el fenómeno de la autorregulación, indicando que existe un amplio campo de estudio para futuros estudios. Además acota el campo de búsqueda reduciendo de forma notable este proceso, y si se puede acelerar el proceso de obtención de una autorregulación de forma más precisa entonces se podrá diagnosticar y tratar a los pacientes de forma anticipada lo que podría ayudar a muchas personas con afecciones del tipo cerebrovascular.

REFERENCIAS

- Aaslid, R., Lindegaard, K., Sorteberg, W., & Nornes, H. (1989). Cerebral autoregulation dynamics in humans. *Stroke*, 20(1), 45-52.
- Amarilla, N., Almeida, C., & Barán, B. (2004). Optimización multi-objetivo para la ubicación de locutorios de cabinas telefónicas. *XXX Conferencia Latinoamericana de Informática*.
- Araya, C. (2006). Modelamiento del sistema de autorregulación cerebral en presencia de CO₂ usando máquinas de vectores soporte. *Tesis conducente al grado de Magíster en Ingeniería Informática, Universidad de Santiago de Chile, Santiago*.
- Bello, F. (2007). Modelamiento multivariado del sistema de autorregulación cerebral utilizando PCC y EtCO₂ mediante máquinas de vectores soporte. *Tesis conducente al grado de Magíster en Ingeniería Informática, Universidad de Santiago de Chile, Santiago*.
- Boser, B., Guyon, I., & Vapnik, V. (1992). A training algorithm for optimal margin classifiers. *ACM*, 144-152.
- Bülent, U. (2003). A comparison of support vector machines and partial least squares regression on spectral data. *Masterthesis, Department of Analytical Chemistry. Katholieke Universiteit Nijmegen, Netherlands*.
- Burges, C. (1998). A Tutorial on Support Vector Machines for Pattern Recognition. *Data Mining and Knowledge Discovery*, 121-167.
- Burgos, C. (2014). Entrenamiento Muestral de Modelos Dinámicos con SVM. *Tesis conducente al grado de Magíster en Ingeniería Informática, Universidad de Santiago de Chile, Santiago*.
- Busija, D. (1993). Cerebral autoregulation: The Regulation of Cerebral Blood Flow. *Ed J. W. Phillis*, 45–64.
- Caramia, M., & Dell'Olmo, P. (2008). Multi-objective Management in Freight Logistics - Increasing Capacity, Service Level and Safety with Optimization Algorithms. *Springer*.
- Chacón, M. (2009). Comparison between SVM and ANN for modeling the cerebral autoregulation blood flow system. *ICN 2009_14*.
- Chacón, M., Araya, C., & B. Panerai, R. (2011). Non-linear multivariate modeling of cerebral hemodynamics with autoregressive Support Vector Machines. *Medical Engineering & Physics*, 33, 180-187.
- Chacón, M., Blanco, C., Panerai, B., & Evans, D. (2005). Nonlinear modeling of dynamic cerebral autoregulation using recurrent neural networks. *Progress in Pattern Recognition, Image Analysis and Applications, Proceedings*, 3773, 205-213.
- Chacón, M., Jara, J. L., & B. Panerai, R. (2014). A New Model-Free Index of Dynamic Cerebral Blood Flow Autoregulation. *PLoS One*, 9(10), 1-11.

- Chacón, M., Nuñez, N., Henríquez, C., & Panerai, R. (2008). Unconstrained parameter estimation for assessment of dynamic cerebral autoregulation. *Physiological Measurement*, 29(10), 1179–1193.
- Chapra, S., & Canale, R. (2006). Numerical methods for engineers. 5th edition. Ed. McGraw-Hill.
- Chaudhari, P., Dharaskar, R., & Thakare, V. (2010). Computing the most significant solution from pareto from obtained in multi-objective evolutionary. *International Journal of Advanced Computer Science and Applications*.
- Coello, C. (2003). Evolutionary Multi-Objective Optimization: A Critical Review. In: Evolutionary Optimization. International Series in Operations Research & Management Science. Springer, vol 48.
- Cortes, C., & Vapnik, V. (1995). Support Vector Networks. *Machine Learning*. 20, 273-297.
- Czosnyka, M., Smielewski, P., Piechnik, S., Steiner, L., & Pickard, J. (2001). Cerebral autoregulation following head injury. *Journal of Neurosurgery*, 95(5), 756-763.
- Deb, K. (2001). Multi-objective Optimization Using Evolutionary Algorithms. *John Wiley & Sons*, 33-43.
- Díaz, D. (2005). Modelamiento del Sistema de Autorregulación Cerebral en Presencia de Cambios de Presión Inducidos en los Muslos utilizando Máquinas de vectores Soporte. *Tesis conducente al grado de Magíster en Ingeniería Informática: Universidad de Santiago de Chile*.
- Erkut, E., Tjandra, S., & Verter, V. (2007). Hazardous materials transportation. *Handbooks in operations and management science*.
- Gajardo, N. (2014). Análisis Comparativo entre Métodos para el Cálculo de la Autorregulación Cerebral que usan cambios Bruscos de Presión y Variaciones Espontáneas utilizando SVM. *Tesis conducente al grado de Magíster en Ingeniería Informática, Universidad de Santiago de Chile, Santiago*.
- Greenfield, J., Rembert, J., & Tindall, G. (1984). Transient changes in cerebral vascular resistance during the Valsalva maneuver in man. *Stroke*, 15(1), 76-79.
- Gunn, S. (1998). Support Vector Machines for Classification and Regression. *University of Southampton, Faculty of Engineering, Science and Mathematics, School of Electronics and Computer Science, Southampton*.
- Horiuchi, M., Endo, J., Dobashi, S., Kiuchi, M., Koyama, K., & Subudhi, A. (2016). Effect on progressive normobaric hypoxia on dynamic cerebral autoregulation. *Physiol*.
- Hsu, C. C. (2003). A practical guide to support vector classification. *Department of Computer Science and Information Engineering, National Taiwan University*.
- Jaimes, A., & Coello, C. (2008). An introductions to Multi-Objective Evolutionary Algorithms and Some of Their Potential Uses in Biology. *Studies in Computational Intelligence, Springer*, 122, 79-102.

- Lang, E., Mehdorn, H., Dorsch, N., & Czosnyka, M. (2002). Continuous monitoring of cerebrovascular autoregulation: a validation study. *Neurol Neurosurg Psych*, 72:583–6.
- Lassen, N. (1959). Cerebral Blood Flow and oxygen consumption in man. *Physiological Reviews*, 183-238.
- Mahony, P., Panerai, R., Deverson, S., Hayes, P., & Evans, D. (2000). Assessment of the Thigh Cuff Technique for Measurement of Dynamic Cerebral Autoregulation. *Stroke*, 31(2), 476-480.
- Miranda, R. (2016). Evaluación de la Autorregulación en Sujetos Normocápnicos e Hipercápnicos usando SVM. *Memoria de Título profesional de Ingeniero Civil en Informática, Universidad de Santiago de Chile, Santiago*.
- Mitsis, D., Debert, C., Hajo, M., Marmarelis, V., & Poulin, M. (2007). Nonlinear, multiple-input modeling of cerebral hemodynamics during baseline and hypercapnia in young and post-menopausal women. *Engineering in Medicine and Biology Society, 2007. EMBS 2007. 29th Annual International Conference of the IEEE* (págs. 2855-2858). Lyon: IEEE.
- Mitsis, G., Zhang, R., Levine, B., & Marmarelis, V. (2002). Modeling of Nonlinear Physiological Systems with Fast and Slow Dynamics II Application to Cerebral Autoregulation. *Annals of Biomedical Engineering*, 30, 555-565.
- Mitsis, G., Zhang, R., Levine, B., & Marmarelis, V. (2006). Cerebral hemodynamics during orthostatic stress assessed by nonlinear modeling. *Journal of Applied Physiology*, 101, 354-366.
- Muñoz, H. (2009). Modelamiento no lineal del sistema de autorregulación cerebral con retroalimentación por distensibilidad intracraneal. *Tesis conducente al grado de Ingeniería Civil Informática, Universidad de Santiago de Chile, Santiago*.
- Nagrath, D., Bequette, B., & Cramer, S. (2005). Multiobjective Optimization Strategies for Linear Gradient Chromatography. *Wile Interscience, Rensselaer Polytechnic Institute. New York*.
- Newell, D., Aaslid, R., Lam, A., Mayberg, T., & Winn, R. (1994). Comparison of flow and velocity during autoregulation testing in humans. *Stroke*, 25, 793-797.
- Ngatchou, P., Zarei, A., & El-Sharkawi, A. (2005). Pareto Multi Objective Optimization. *IEEE Xplore*.
- Noh, S. (2014). Comparación de los Métodos de Cálculo de Autorregulación con la Maniobra “Sit-to-stand” y Variaciones Espontáneas de Presión. *Tesis conducente al grado de Ingeniería Civil Informática, Universidad de Santiago de Chile, Santiago*.
- Nuñez, N. (2003). Modelamiento lineal y no lineal del sistema de autorregulación cerebral en presencia de cambios de presión inducidos en los muslos. *Tesis conducente al grado de Magíster en Ingeniería Informática, Universidad de Santiago de Chile, Santiago*.
- Panerai, R. (1998). Assessment of cerebral pressure autoregulation in humans—a review of measurement methods. *Physiological Measurement*, 19(3), 305–338.

- Panerai, R., Chacon, M., Pereira, R., & Evans, D. (2004). Neural Network Modelling of Dynamic Cerebral Autoregulation: Assessment and Comparison with Established Methods. *Medical Engineering and Physics*, 26, 43-52.
- Panerai, R., Dawson, S., & Potter, J. (1999a). Linear and nonlinear analysis of human dynamic cerebral autoregulation. *Am J Physiol*, 227, 1089-1099.
- Panerai, R., Dawson, S., Eames, P., & Potter, J. (2001). Cerebral blood flow velocity response to induced and spontaneous sudden changes in arterial blood pressure. *American Journal of Physiology - Heart and Circulatory Physiology*, 280, 2162-2174.
- Panerai, R., Deverson, S., Mahony, P., Hayes, P., & Evans, D. (1999b). Effect of CO₂ on dynamic cerebral autoregulation measurement. *Physiological Measurement*, 20(3), 265–275.
- Panerai, R., Eames, P., & Potter, J. (2003). Variability of time-domain indices of dynamic cerebral autoregulation. *Physiol Meas*, 367-381.
- Panerai, R., James, M., & Potter, J. (1997). Impulse Response Analysis of Baroreceptor Sensitivity. *Am. J. Physiol*, 272, 1866-1875.
- Ramos, E., Simpson, D., Panerai, R., Nadal, J., Lopes, J., & Evans, D. (2006). Objective selection of signals for assessment of cerebral blood flow autoregulation in neonates. *Physiological Measurement*, 27(1), 35-49.
- Ruz, J. (2009). Modelamiento no lineal del Sistema de Autorregulación Cerebral y su Asociación con la Predicción de Mortalidad en Pacientes con Traumatismo Encéfalo Craneano. *Tesis conducente al grado de Magíster en Ingeniería Informática, Universidad de Santiago de Chile, Santiago*.
- Schölkopf, B., Smola, A., Williamson, R., & Bartlett, P. (2000). New support vector algorithms. *Neural Computation*, 12(5), 1207-1245.
- Smola, A. (1996). Regression Estimation with Support Vector Learning Machines. *Alemania: Tesis conducente al grado de Magíster, Physik Department, Technische Universität München*.
- Smola, A., & Schölkopf, B. (1998a). *A Tutorial on Support Vector Regression*. NeuroCOLT Technical Report Series NC2-TR-1998-030.
- Smola, A., Murata, N., Schölkopf, B., & Klaus-Robert. (1998b). Asymptotically Optimal Choice of of epsilon-Loss for Support Vector Machines. *8th International Conference on Artificial Neural Networks*, 105-110.
- Taha, H. (2012). *Investigación de operaciones 9a edición*. Pearson Education.
- Tiecks, F., Lam, A., Aaslid, R., & Newell, D. (1995). Comparison of Static and Dynamic Cerebral Autoregulation Measurements. *American Heart Association*, 26(6), 1014-1019.
- Vapnik, V. (1995). *The Nature of Statistical Learning Theory*. New York, EEUU: Springer.
- Vapnik, V., & Chervonenkis, A. (1971). On the uniform convergence of relative frequencies of events to their probabilities. *Theory of Probability & Its Applications*, 16(2), 264-280.
- Vapnik, V., & Lerner, A. (1963). Pattern recognition using generalized portrait method. *Automation and Remote Control*, 24, 774-780.

- Vapnik, V., Golowich, S., & Smola, A. (1997). Support Vector Method for Function Aproximation, Regression Estimation and Signal Processing. *Advances in Neural Information Processing Systems*, 9, 281-287.
- Varas, N. (2013). Construcción de modelos para evaluar la autorregulación de pacientes con traumatismo encéfalo craneano usando modelo FIR y NFIR con SVM. *Tesis conducente al grado de Magíster en Ingeniería Informática, Universidad de Santiago de Chile, Santiago*.
- Zitzler, E., Laumans, M., & Thiele, L. (2001). SPEA2: improving the Strength Pareto Evolutionary Algorithm. *Swiss Federal Institute of Technology (ETH). Zurich*.

APÉNDICE A. ÍNDICES AUTORREGULATORIOS

Índices autorregulatorios ARI promediados

TABLA A-1: Índices autorregulatorios ARI promediados por modelo de aprendizaje, obtenidos mediante la optimización multi-objetivo.

Sujeto	FIR	NFIR	ARX	NARX
1	1,2	2,6	0,2	1,9
2	2,8	3,7	2,5	1
3	9	6,8	2,1	2,4
4	2,7	3,6	2	1,7
5	6,6	4	2,5	1,5
6	3,4	3,7	1,7	2,3
7	7,3	5,7	1,6	1,4
8	4	4,9	1,2	1
9	9	3,7	2,5	1,2
10	3,9	3	2	1
11	3,7	3,2	2,1	1,8
12	4,6	5,3	1,2	2,5
13	4,4	4,5	2	0,5
14	4,3	6,9	2,4	3,5
15	2,6	3,9	2,1	1,9
16	3,8	4,2	1,8	1,2
Media \pm SD	4,6 \pm 2,26	4,4 \pm 1,26	1,9 \pm 0,60	1,7 \pm 0,75

Índices autorregulatorios mfARI promediados

TABLA A-2: Índices autorregulatorios mfARI promediados por modelo de aprendizaje, obtenidos mediante la optimización multi-objetivo.

Sujeto	FIR	NFIR	ARX	NARX
1	2,5	3,7	1,2	1,4
2	4,1	4,9	2,1	1,8
3	7	7,8	1,3	2,1
4	3,4	5,1	1,8	1,5
5	7	4,8	2,4	1,4
6	4,8	5,3	1,5	2
7	7,2	7,1	2,6	1,7
8	5,8	6,5	1,4	1,4
9	6,5	5,6	2,1	2
10	5,7	3,5	1,5	1,4
11	5,2	3,4	1,4	1,8
12	6	6	1,5	2,6
13	6,1	6,3	2,1	1,8
14	4,4	7,2	1,9	4,8
15	1,8	5,5	1,5	1,9
16	5,4	5,9	1,3	1,9
Media \pm SD	5,2 \pm 1,60	5,5 \pm 1,30	1,7 \pm 0,43	2,0 \pm 0,82

Índices autorregulatorios obtenidos por el filtro avanzado

TABLA A-3: Índices autorregulatorios ARI por modelo de aprendizaje, obtenidos por el filtro avanzado.

Sujeto	FIR	NFIR	ARX	NARX
1	3,2	3,2	2,2	1,6
2	2,7	2,9	3,6	6,7
3	6,2	5,0	6,5	6,7
4	3,0	3,6	3,5	4,1
5	4,5	5,3	2,8	3,9
6	3,8	3,7	3,7	6,6
7	6,3	3,2	4,0	1,6
8	5,8	6,1	4,9	4,3
9	9,0	8,1	8,1	8,0
10	3,8	3,8	3,9	3,8
11	4,0	8,6	6,3	2,2
12	4,3	7,2	3,6	8,6
13	4,6	3,9	5,0	4,0
14	5,8	5,0	6,1	6,6
15	-	9,0	4,6	5,8
16	4,2	4,3	4,4	8,6
Media \pm SD	4,7 \pm 1,63	5,2 \pm 2,03	4,6 \pm 1,53	5,2 \pm 2,33

TABLA A-4: Índices autorregulatorios mfARI por modelo de aprendizaje, obtenidos por el filtro avanzado.

Sujeto	FIR	NFIR	ARX	NARX
1	4,8	4,6	3,3	2,7
2	4,1	4,8	4,0	8,3
3	7,5	6,7	6,9	7,1
4	4,8	5,7	4,2	5,1
5	6,6	7,0	2,9	5,3
6	5,7	5,3	5,9	7,9
7	6,9	3,5	4,9	3,9
8	7,0	6,9	6,7	5,9
9	7,3	7,4	8,3	8,5
10	6,0	5,9	7,0	5,6
11	5,2	8,4	7,4	1,1
12	5,7	9,1	5,7	8,0
13	6,2	5,4	6,0	5,3
14	6,8	6,7	6,9	7,1
15	-	9,1	5,3	7,9
16	5,3	5,4	6,2	8,2
Media \pm SD	6,0 \pm 1,02	6,4 \pm 1,6	5,7 \pm 1,53	6,1 \pm 2,18

APÉNDICE B. ÍNDICES DE CALIDAD

Índices de calidad frente de Pareto

TABLA B-1: Promedios de las calidades de los individuos por método de aprendizaje para el frente de Pareto.

Sujeto	FIR	NFIR	ARX	NARX
1	7,8	7,9	6,5	6,7
2	9,7	9,2	7,9	7,5
3	8,6	7,7	5,7	6,5
4	8,2	8,6	6,6	6,3
5	8,7	8,3	6,6	5,6
6	9,7	9,3	6,8	7,3
7	8,9	8,4	6,5	5,6
8	9,1	8,6	5,9	5,9
9	9,4	9,6	6,2	6,1
10	9,8	7,6	5,9	5,8
11	8,5	6,5	4,7	5,1
12	9,2	9	5,1	6,2
13	8,8	8,6	7,2	6,9
14	7,5	8,6	5	7,9
15	7,7	8,5	7,4	7,8
16	8,5	8,9	4,4	5
Media \pm SD	8,9 \pm 0,81	8,9 \pm 0,83	6,15 \pm 0,99	6,4 \pm 0,89

Índices de calidad filtro avanzado

TABLA B-2: Promedio de las calidades de los individuos por método de aprendizaje para el filtro avanzado.

Sujeto	FIR	NFIR	ARX	NARX
1	9,9	9,9	8,6	8
2	9,9	9,4	9,8	5,9
3	8,1	8,9	8,7	8,5
4	9,6	9,5	9	9,9
5	9,2	8,8	7,1	9,5
6	9	9,4	8,8	6,8
7	9,2	7,4	8,8	7,8
8	8,5	8,6	8,8	9,6
9	8,6	8,5	7,6	7,4
10	9,6	9,7	8,6	10
11	8,5	8,3	9,3	4,4
12	9,3	7,3	9,3	8,4
13	8,7	9,5	8,9	9,6
14	9,9	9,8	10	9,8
15	-	5	8,8	6,2
16	8,4	8,5	9,3	8,7
Media \pm SD	9,1 \pm 0,60	8,7 \pm 1,25	8,8 \pm 1,71	8,2 \pm 1,66

APÉNDICE C. REGLAS DE ASOCIACIÓN

Aprendizaje FIR

TABLA C-1: Reglas de Asociación para el subfrente de Pareto en aprendizaje FIR. Fuente: Elaboración Propia, 2017.

Cantidad	Transacción	Soporte	Confianza	Mejora de la confianza
48	{CORR=(0.5,0.75]} => {CALIDAD=MUY ALTA}	0,302	0,565	1,425
46	{RET=(5,10]} => {CALIDAD=ALTA}	0,289	0,590	1,116
40	{nu=0.1} => {CALIDAD=ALTA}	0,252	0,615	1,165
40	{VS=(0,50]} => {CALIDAD=ALTA}	0,252	0,606	1,147
40	{COSTO=(0,32]} => {CALIDAD=ALTA}	0,252	0,476	0,901
40	{VS=(0,50],nu=0.1} => {CALIDAD=ALTA}	0,252	0,615	1,165

Aprendizaje ARX

TABLA C-2: Reglas de Asociación para el subfrente de Pareto en aprendizaje ARX. Fuente: Elaboración Propia, 2017.

Cantidad	Transacción	Soporte	Confianza	Mejora de la confianza
810	{nu=0.1} => {CALIDAD=NORMAL}	0,58	0,599	1,033
810	{VS=(0,50]} => {CALIDAD=NORMAL}	0,58	0,580	1,000
810	{COSTO=(0,32]} => {CALIDAD=NORMAL}	0,58	0,580	1,000
810	{VS=(0,50],nu=0.1} => {CALIDAD=NORMAL}	0,58	0,599	1,033
810	{nu=0.1,COSTO=(0,32]} => {CALIDAD=NORMAL}	0,58	0,599	1,033
810	{VS=(0,50],COSTO=(0,32]} => {CALIDAD=NORMAL}	0,58	0,580	1,000
810	{VS=(0,50],nu=0.1,COSTO=(0,32]} => {CALIDAD=NORMAL}	0,58	0,599	1,033
759	{CORR=(0.75,1]} => {CALIDAD=NORMAL}	0,543	0,579	0,999
759	{nu=0.1,CORR=(0.75,1]} => {CALIDAD=NORMAL}	0,543	0,600	1,034
759	{VS=(0,50],CORR=(0.75,1]} => {CALIDAD=NORMAL}	0,543	0,579	0,999
759	{COSTO=(0,32],CORR=(0.75,1]} => {CALIDAD=NORMAL}	0,543	0,579	0,999
759	{VS=(0,50],nu=0.1,CORR=(0.75,1]} => {CALIDAD=NORMAL}	0,543	0,600	1,034

Cantidad	Transacción	Soporte	Confianza	Mejora de la confianza
759	{nu=0.1,COSTO=(0,32], CORR=(0.75,1]} => {CALIDAD=NORMAL}	0,543	0,600	1,034
759	{VS=(0,50],COSTO=(0,32], CORR=(0.75,1]} => {CALIDAD=NORMAL}	0,543	0,579	0,999
759	{VS=(0,50],nu=0.1,COSTO=(0,32], CORR=(0.75,1]} => {CALIDAD=NORMAL}	0,543	0,600	1,034
474	{VS=(0,50]} => {CALIDAD=BAJA}	0,339	0,339	1,000
474	{COSTO=(0,32]} => {CALIDAD=BAJA}	0,339	0,339	1,000
474	{VS=(0,50],COSTO=(0,32]} => {CALIDAD=BAJA}	0,339	0,339	1,000
438	{CORR=(0.75,1]} => {CALIDAD=BAJA}	0,314	0,334	0,985
438	{VS=(0,50],CORR=(0.75,1]} => {CALIDAD=BAJA}	0,314	0,334	0,985
438	{COSTO=(0,32],CORR=(0.75,1]} => {CALIDAD=BAJA}	0,314	0,334	0,985
438	{VS=(0,50],COSTO=(0,32], CORR=(0.75,1]} => {CALIDAD=BAJA}	0,314	0,334	0,985
430	{nu=0.1} => {CALIDAD=BAJA}	0,308	0,318	0,937
430	{VS=(0,50],nu=0.1} => {CALIDAD=BAJA}	0,308	0,318	0,937
430	{nu=0.1,COSTO=(0,32]} => {CALIDAD=BAJA}	0,308	0,318	0,937
430	{VS=(0,50],nu=0.1,COSTO=(0,32]} => {CALIDAD=BAJA}	0,308	0,318	0,937
394	{nu=0.1,CORR=(0.75,1]} => {CALIDAD=BAJA}	0,282	0,311	0,917
394	{VS=(0,50],nu=0.1, CORR=(0.75,1]} => {CALIDAD=BAJA}	0,282	0,311	0,917
394	{nu=0.1,COSTO=(0,32], CORR=(0.75,1]} => {CALIDAD=BAJA}	0,282	0,311	0,917
394	{VS=(0,50],nu=0.1,COSTO=(0,32], CORR=(0.75,1]} => {CALIDAD=BAJA}	0,282	0,311	0,917
373	{RET=(5,10]} => {CALIDAD=NORMAL}	0,267	0,625	1,078
373	{nu=0.1,RET=(5,10]} => {CALIDAD=NORMAL}	0,267	0,653	1,127
373	{VS=(0,50],RET=(5,10]} => {CALIDAD=NORMAL}	0,267	0,625	1,078
373	{COSTO=(0,32],RET=(5,10]} => {CALIDAD=NORMAL}	0,267	0,625	1,078
373	{VS=(0,50],nu=0.1,RET=(5,10]} => {CALIDAD=NORMAL}	0,267	0,653	1,127

Cantidad	Transacción	Soporte	Confianza	Mejora de la confianza
373	{nu=0.1,COSTO=(0,32], RET=(5,10]} => {CALIDAD=NORMAL}	0,267	0,653	1,127
373	{VS=(0,50],COSTO=(0,32], RET=(5,10]} => {CALIDAD=NORMAL}	0,267	0,625	1,078
373	{VS=(0,50],nu=0.1,COSTO=(0,32], RET=(5,10]} => {CALIDAD=NORMAL}	0,267	0,653	1,127
355	{CORR=(0.75,1],RET=(5,10]} => {CALIDAD=NORMAL}	0,254	0,638	1,101
355	{nu=0.1,CORR=(0.75,1], RET=(5,10]} => {CALIDAD=NORMAL}	0,254	0,670	1,155
355	{VS=(0,50],CORR=(0.75,1], RET=(5,10]} => {CALIDAD=NORMAL}	0,254	0,638	1,101
355	{COSTO=(0,32],CORR=(0.75,1], RET=(5,10]} => {CALIDAD=NORMAL}	0,254	0,638	1,101
355	{VS=(0,50],nu=0.1,CORR=(0.75,1], RET=(5,10]} => {CALIDAD=NORMAL}	0,254	0,670	1,155
355	{nu=0.1,COSTO=(0,32], CORR=(0.75,1], RET=(5,10]} => {CALIDAD=NORMAL}	0,254	0,670	1,155
355	{VS=(0,50],COSTO=(0,32], CORR=(0.75,1],RET=(5,10]} => {CALIDAD=NORMAL}	0,254	0,638	1,101
355	{VS=(0,50],nu=0.1,COSTO=(0,32], CORR=(0.75,1],RET=(5,10]} => {CALIDAD=NORMAL}	0,254	0,670	1,155

Aprendizaje NFIR

TABLA C-3: Reglas de Asociación para el subfrente de Pareto en aprendizaje NFIR. Fuente: Elaboración Propia, 2017.

Cantidad	Transacción	Soporte	Confianza	Mejora de la confianza
130	{COSTO=(0,32]} => {CALIDAD=MUY ALTA}	0,281	0,414	1,065
125	{COSTO=(0,32]} => {CALIDAD=ALTA}	0,270	0,398	0,975

Aprendizaje NARX

TABLA C-4: Reglas de Asociación para el subfrente de Pareto en aprendizaje NARX. Fuente: Elaboración Propia, 2017.

Cantidad	Transacción	Soporte	Confianza	Mejora de la confianza
1642	{CORR=(0.75,1]} => {CALIDAD=NORMAL}	0,700	0,700	1,000
948	{RET=(5,10]} => {CALIDAD=NORMAL}	0,404	0,776	1,110
948	{CORR=(0.75,1],RET=(5,10]} => {CALIDAD=NORMAL}	0,404	0,776	1,110
861	{COSTO=(0,32]} => {CALIDAD=NORMAL}	0,367	0,657	0,939
861	{COSTO=(0,32],CORR=(0.75,1]} => {CALIDAD=NORMAL}	0,367	0,657	0,939
681	{VS=(50,100]} => {CALIDAD=NORMAL}	0,290	0,657	0,940
681	{VS=(50,100],CORR=(0.75,1]} => {CALIDAD=NORMAL}	0,290	0,657	0,940

APÉNDICE D. MODELOS DE AUTORREGULACIÓN

Modelos seleccionados en estudio de filtro avanzado

TABLA D-1: Modelos seleccionados FIR.

Sujeto	Retardos		Parámetros		Entrenamiento		Validación	
	PAM	EtCO ₂	ν	C	CC	ECMNa	CC	ECMNa
1	3	4	0,7	16384	0,697	0,512	0,701	0,506
2	3	1	0,7	8192	0,646	0,581	0,704	0,503
3	7	5	0,8	16384	0,562	0,681	0,355	0,871
4	5	6	0,4	16384	0,583	0,658	0,803	0,353
5	5	5	0,8	8192	0,516	0,732	0,694	0,516
6	6	2	0,2	16384	0,654	0,571	0,697	0,512
7	6	5	0,7	16384	0,510	0,737	0,480	0,767
8	8	5	0,6	16384	0,507	0,740	0,653	0,572
9	7	3	0,9	16384	0,679	0,537	0,663	0,559
10	6	2	0,3	2	0,625	0,607	0,769	0,407
11	4	6	0,1	4	0,610	0,624	0,500	0,746
12	8	3	0,5	8192	0,807	0,348	0,648	0,579
13	8	5	0,6	8192	0,860	0,259	0,874	0,236
14	8	6	0,9	16384	0,684	0,530	0,838	0,296
15	-	-	-	-	-	-	-	-
16	8	5	0,1	4	0,834	0,303	0,847	0,281
	8	5	0,55 ± 0,27	10923,33 ± 6687,57	0,652 ± 0,113	0,561 ± 0,154	0,682 ± 0,145	0,514 ± 0,183
	Moda		Media ± SD					

TABLA D-2: Modelos seleccionados ARX.

Sujeto	Retardos			Parámetros		Entrenamiento		Validación	
	PAM	EtCO ₂	VFSC	ν	C	CC	ECMNa	CC	ECMNa
1	7	0	3	0,6	8192	0,963	0,073	0,820	0,326
2	5	0	4	0,9	2048	0,996	0,007	0,685	0,528
3	4	0	6	0,7	16384	0,886	0,215	0,485	0,762
4	2	4	4	0,4	4096	0,976	0,048	0,808	0,345
5	2	5	2	0,7	16384	0,978	0,043	0,795	0,366
6	5	6	2	0,5	256	0,991	0,017	0,731	0,464
7	6	6	4	0,4	8192	0,980	0,039	0,641	0,587
8	8	6	5	0,5	512	0,998	0,004	0,707	0,498
9	6	0	6	0,4	32	0,989	0,022	0,774	0,400
10	8	3	4	0,9	1024	0,976	0,047	0,735	0,458
11	1	1	6	0,1	8192	0,963	0,071	0,725	0,471
12	2	4	4	0,5	16384	0,984	0,031	0,820	0,327
13	8	4	4	0,5	1024	0,998	0,005	0,904	0,182
14	4	3	2	0,4	16384	0,977	0,046	0,853	0,271
15	5	6	5	0,3	8192	0,993	0,013	0,580	0,661
16	3	3	2	0,9	64	0,988	0,024	0,869	0,243
	5	0	4	0,54 ± 0,23	6710 ± 6558,42	0,977 ± 0,027	0,044 ± 0,05	0,746 ± 0,11	0,431 ± 0,155
	Moda			Media ± SD					

TABLA D-3: Modelos seleccionados NFIR.

Sujeto	Retardos		Parámetros			Entrenamiento		Validación	
	PAM	EtCO ₂	σ	ν	ζ	CC	ECMNa	CC	ECMNa
1	2	1	1	0,7	2	0,748	0,439	0,701	0,507
2	2	0	64	0,7	8192	0,648	0,578	0,703	0,504
3	8	3	8	0,7	16384	0,681	0,534	0,473	0,774
4	3	6	4	0,2	1024	0,758	0,424	0,824	0,320
5	5	4	8	0,2	4096	0,634	0,596	0,797	0,364
6	2	5	16	0,1	512	0,641	0,587	0,696	0,514
7	1	5	1	0,8	4	0,681	0,534	0,602	0,635
8	6	4	8	0,9	64	0,580	0,661	0,696	0,514
9	6	0	4	0,1	32	0,668	0,551	0,663	0,558
10	6	2	64	0,3	8192	0,626	0,606	0,770	0,406
11	8	4	2	0,1	512	0,729	0,466	0,511	0,734
12	3	1	1	0,3	8	0,852	0,273	0,681	0,535
13	8	5	32	0,7	16384	0,872	0,240	0,868	0,245
14	4	6	8	0,9	64	0,777	0,395	0,825	0,319
15	1	5	0	0,1	8192	0,921	0,151	0,453	0,792
16	8	5	64	0,1	16384	0,836	0,301	0,848	0,281
	8	5	17,8 ± 24,21	0,43 ± 0,32	5002,88 ± 6452,56	0,728 ± 0,101	0,459 ± 0,151	0,694 ± 0,13	0,5 ± 0,172
	Moda		Media ± SD						

TABLA D-4: Modelos seleccionados NARX.

Sujeto	Retardos			Parámetros			Entrenamiento		Validación	
	PAM	EtCO ₂	VFSC	σ	ν	ζ	CC	ECMNa	CC	ECMNa
1	4	3	3	2	0,6	512	0,974	0,050	0,805	0,351
2	1	1	2	1	0,1	8192	0,993	0,013	0,696	0,514
3	7	2	2	4	0,1	8192	0,956	0,085	0,607	0,629
4	3	0	2	32	0,1	16384	0,967	0,065	0,797	0,364
5	4	1	4	4	0,1	1024	0,991	0,018	0,869	0,245
6	7	6	3	4	0,6	256	0,995	0,010	0,693	0,518
7	1	4	4	2	0,1	256	0,988	0,023	0,602	0,636
8	2	1	2	2	0,5	8192	0,997	0,006	0,680	0,536
9	6	0	4	32	0,2	8192	0,984	0,031	0,763	0,416
10	7	1	2	32	0,1	4096	0,968	0,063	0,756	0,427
11	1	1	1	1	0,4	16	0,938	0,119	0,730	0,464
12	2	1	2	16	0,1	16384	0,982	0,035	0,750	0,436
13	7	3	2	32	0,6	16384	0,997	0,007	0,895	0,199
14	5	6	5	4	0,2	64	0,983	0,034	0,871	0,240
15	3	0	1	1	0,3	512	0,994	0,012	0,687	0,527
16	4	0	2	8	0,1	4096	0,988	0,024	0,869	0,243
	7	1	2	11,06 ± 13	0,26 ± 0,21	5797 ± 6171,55	0,981 ± 0,016	0,037 ± 0,032	0,754 ± 0,092	0,422 ± 0,138
	Moda			Media ± SD						